



Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ «Робототехника и комплексная автоматизация»

КАФЕДРА «Системы автоматизированного проектирования (РК-6)»

**РАСЧЕТНО-ПОЯСНИТЕЛЬНАЯ ЗАПИСКА
К ВЫПУСКНОЙ КВАЛИФИКАЦИОННОЙ РАБОТЕ**

НА ТЕМУ:

**«Обнаружение аномалий в биомедицинских сигналах
с использованием рекуррентных нейронных сетей»**

Студент группы РК6-81Б

(Подпись, дата)

А. В. Арбузова

Руководитель ВКР

(Подпись, дата)

Т. М. Волосатова

Консультант

(Подпись, дата)

А. Ю. Спасёнов

Нормоконтролер

(Подпись, дата)

С. В. Грошев

2020 г.

РЕФЕРАТ

Целью работы является разработка алгоритма, выделяющего аномальные данные в необработанных цифровых биомедицинских сигналах.

В рамках работы было проведено исследование наиболее известных существующих подходов к обнаружению аномалий в биомедицинских сигналах. Произведен сравнительный анализ таких методов предварительной обработки сигналов, как вейвлет-преобразования, фильтр Баттервортса и фильтр скользящего среднего значения. Выявлена оптимальная архитектура нейронной сети для выполнения поставленной задачи – рекуррентный автокодировщик с модулями долгой краткосрочной памяти.

Для реализации описываемых методов был использован язык программирования Python.

В качестве экспериментальных данных для проведения исследований были использованы цифровые записи физиологических сигналов, находящиеся в открытом доступе в интернет-портале PhysioNet.

Ключевые слова: временной ряд, контекстуальные аномалии, непрерывное вейвлет-преобразование, дискретное вейвлет-преобразование, фильтр Баттервортса, автокодировщик, рекуррентная нейронная сеть, рекуррентная нейронная сеть с долгой краткосрочной памятью, аугментация данных.

Расчетно-пояснительная записка содержит 64 страницы, 39 иллюстраций, 27 источников информации, 1 приложение.

СОДЕРЖАНИЕ

РЕФЕРАТ	6
ВВЕДЕНИЕ	9
1. Описание предметной области	10
1.1. Временные ряды	10
1.2. Классификация аномалий	11
2. Постановка задачи	14
3. Этап предварительной обработки сигнала	15
3.1. Структура электрокардиограммы	15
3.2. Разновидности искажений на электрокардиограммах	16
3.3. Линейные цифровые фильтры для преобразования сигналов	19
3.4. Частотно-временные преобразования сигналов	21
3.4.1. Непрерывное преобразование Фурье	21
3.4.2. Дискретное преобразование Фурье	23
3.4.3. Непрерывное вейвлет-преобразование	25
3.4.4. Диадное вейвлет-преобразование	28
3.4.5. Быстрое вейвлет-преобразование	29
3.5. Сравнительный анализ различных методов фильтрации на реальных данных	32
4. Этап обнаружения аномалий	37
4.1. Рекуррентные нейронные сети	37
4.2. Архитектура рекуррентной сети с долгой краткосрочной памятью	38
4.3. Автокодировщик	43
4.4. LSTM-автокодировщик	45
4.5. Аугментация данных	46
5. Описание разработанного алгоритма	49
5.1. Используемые программные средства	49
5.2. Программная реализация	50
5.3. Визуализация результатов работы алгоритма	55

ЗАКЛЮЧЕНИЕ	61
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	62
ПРИЛОЖЕНИЕ А Графическая часть выпускной квалификационной работы.	65

ВВЕДЕНИЕ

Обработка биомедицинских сигналов проводится с целью выделения информативных, с точки зрения медицинской диагностики, признаков или с целью определения диагностических показателей, вычисляемых по параметрам сигнала. С обработкой биомедицинских сигналов тесно связана эффективность современных медицинских технологий. Качественная обработка данных, полученных в результате мониторинга, нужна для корректной оценки клинического состояния пациента. Подобная диагностика позволяет своевременно обнаружить существующие патологии и подобрать надлежащее лечение. Поэтому задача обнаружения аномалий является чрезвычайно актуальной в сфере здравоохранения.

Задача обнаружения аномалий относится к проблеме поиска паттернов в данных, которые не соответствуют ожидаемому поведению [1]. Проблема обнаружения аномалий является актуальной и востребованной, так как зачастую непредвиденные значения в потоках данных несут критически важную информацию в различных областях применения. К подобным областям относится не только медицина, данная задача находит применение и в банковской сфере (выявление мошеннических операций), информационной безопасности (анализ сетевого трафика), сейсмологии и других предметных областях.

Данная работа посвящена разработке оптимального алгоритма для обнаружения аномалий в биомедицинских сигналах на примере записей электрокардиограмм.

1. Описание предметной области

1.1. Временные ряды

Биомедицинские сигналы представляют собой физические проявления физиологических процессов живого организма, которые могут быть измерены и представлены в виде, удобном для обработки с помощью электронных средств (например, в виде величины электрического напряжения или тока) [2].

Наибольшую диагностическую ценность имеют переменные биосигналы, характеризующие функционирование сердца, центральной нервной системы, опорно-двигательного аппарата, состояние нервно-мышечной проводимости и другие. Примерами таких сигналов являются:

a) Электрокардиографический сигнал

Электрокардиографический сигнал представляет собой изменение во времени электрического потенциала определённых участков кожи, возникающее под действием биоэлектрической активности сердца.

б) Электроэнцефалографический сигнал

Это изменение во времени электрического потенциала определённых участков кожи головы возникающее под действием биоэлектрической активности центральной нервной системы.

в) Электрокортикографический сигнал

Представляет собой изменение во времени электрического потенциала определённых участков головного мозга с помощью электродов, отводящих биопотенциалы непосредственно от коры головного мозга.

Современные электронные приборы, считывающие биомедицинские сигналы, записывают и отображают данные в цифровом формате. Цифровая форма сигнала – это его представление путем генерации последовательности чисел, описывающих дискретный набор его точек. Таким образом, в результате дискретизации исходный сигнал представляется в виде числовой последовательности, зависимой от времени - в форме временного ряда.

Временной ряд – это упорядоченная последовательность отсчетов $X = x_1, x_2, \dots, x_N$, взятых в моменты времени $t = (0, 1, \dots, (N - 1))\Delta t$, где N – общее число отсчетов; Δt – интервал дискретизации. Многомерный временного ряда, содержащий совокупность дискретных отсчетов, полученных по нескольким измерительным каналам, обозначается как $X \in \mathbb{R}^{M \times N}$, где M – общее число каналов [3]. Значениями x_i в случае биомедицинских сигналов являются показания датчиков.

Таким образом, задача обнаружения аномалий в биомедицинских сигналах сводится к задаче обнаружения аномалий во временных рядах.

1.2. Классификация аномалий

Одним из ключевых аспектов при выборе метода обнаружения аномалий является их тип. В связи с этим чрезвычайно важно уметь классифицировать аномалии.

Аномалии в данных могут быть отнесены к одному из трех типов [1]:

а) Точечные аномалии

Возникают в ситуации, когда отдельный экземпляр данных может рассматриваться как аномальный по отношению к остальным данным. На рисунке 1 экземпляры O_1 , O_2 , а также группа экземпляров O_3 являются аномальными при нормальных экземплярах в группах N_1 и N_2 . Данный вид аномалий является наиболее легко распознаваемым, большинство существующих методов создано для распознавания точечных аномалий.

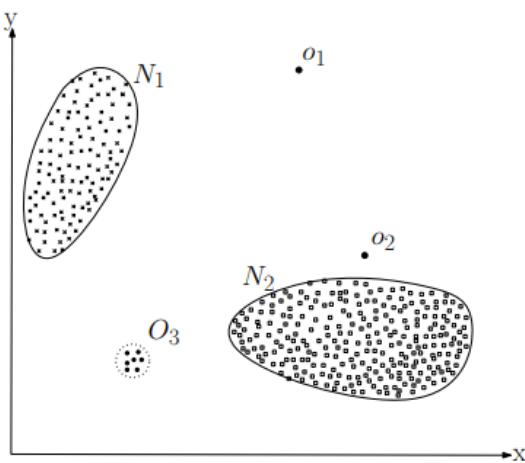


Рисунок 1 – Пример точечных аномалий

б) Контекстуальные аномалии

Наблюдаются, если экземпляр данных является аномальным лишь в определенном контексте (даный вид аномалий также называется условным). Для определения аномалий этого типа основным является выделение контекстуальных и поведенческих атрибутов.

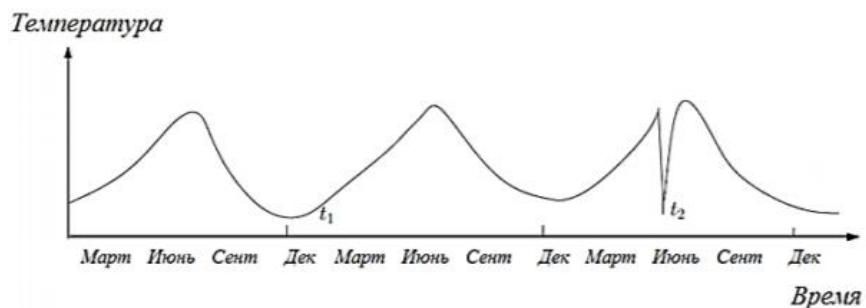


Рисунок 2 - Пример контекстуальных аномалий

Контекстуальные атрибуты используются для определения контекста (или окружения) для каждого экземпляра. Во временных рядах контекстуальным атрибутом является время, которое определяет положение экземпляра в целой последовательности. Контекстуальным атрибутом также могут быть положение в пространстве или более сложные комбинации свойств.

Поведенческие атрибуты определяют не контекстуальные характеристики, относящиеся к конкретному экземпляру данных. Аномальное поведение определяется посредством значений поведенческих атрибутов исходя из конкретного контекста. Таким образом, экземпляр данных может

быть контекстуальной аномалией при данных условиях, но при таких же поведенческих атрибутах считаться нормальным в другом контексте. Например, на рисунке 2 температура в точке t_2 является аномалией, в отличие от точки t_1 , имеющей аналогичное значение, но в другом контексте. При обнаружении контекстуальных аномалий это свойство является ключевым в разделении контекстуальных и поведенческих атрибутов.

в) Коллективные аномалии

Возникают, когда последовательность связанных экземпляров данных (например, участок временного ряда) является аномальной по отношению к целому набору данных. Отдельный экземпляр данных в такой последовательности может не являться отклонением, однако совместное появление таких экземпляров является коллективной аномалией. На рисунке 3 участок A является коллективной аномалией.

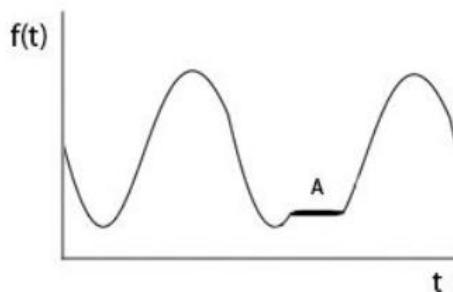


Рисунок 3 - Пример коллективной аномалии

Точечные и контекстуальные аномалии могут наблюдаться в любом наборе данных, в то время как коллективные наблюдаются только в тех, где данные связаны между собой. При этом коллективные аномалии, как и точечные, могут в то же время являться и контекстуальными.

2. Постановка задачи

Для правильной трактовки показателей биомедицинских сигналов важно, чтобы сигналы обладали надлежащим качеством. Качественной является такая запись сигнала, на которой отсутствуют различного рода помехи. Поэтому для автоматизированных систем исследования данных важно наличие этапа предобработки данных. В связи с этим алгоритм, который находит аномалии в данных, должен быть подразделен как минимум на два глобальных этапа: этап предобработки данных и этап непосредственного выделения аномальных участков.

Так как существует множество разновидностей биомедицинских сигналов и каждый вид имеет свои характерные особенности, которые необходимо учитывать в процессе разработки алгоритма, было принято решение проводить разработку алгоритма и его тестирование только для электрокардиограмм.

Исходя из вышеизложенного были поставлены следующие задачи:

- исследовать разновидности шумов в электрокардиограммах;
- провести обзор существующих алгоритмов, служащих для помехоподавления в сигналах;
- провести сравнительный анализ некоторых алгоритмов фильтрации на реальных данных;
- определить оптимальный алгоритм фильтрации;
- провести обзор существующих архитектур нейронных сетей;
- обосновать выбор рекуррентных нейронных сетей для решения поставленной задачи;
- разработать оптимальную модель нейронной сети;
- провести тестирование разработанной модели на синтетических и реальных данных.

3. Этап предварительной обработки сигнала

3.1. Структура электрокардиограммы

Электрокардиограмма (ЭКГ) представляет собой сигнал, описывающий электрическую активность сердца. ЭКГ образуется в результате сокращений (деполяризации) и расслаблений (реполяризации) предсердных и желудочковых мышц сердца [4]. Периодически повторяющаяся кривая биопотенциалов сердца, регистрируемых электрокардиографом, отражает процесс возбуждения сердца, возникшего в синусном (синусно-предсердном) узле и распространяющегося по всему сердцу.

Полученная кривая включает следующие элементы: зубцы, сегменты и интервалы, все они представлены на рисунке 4.

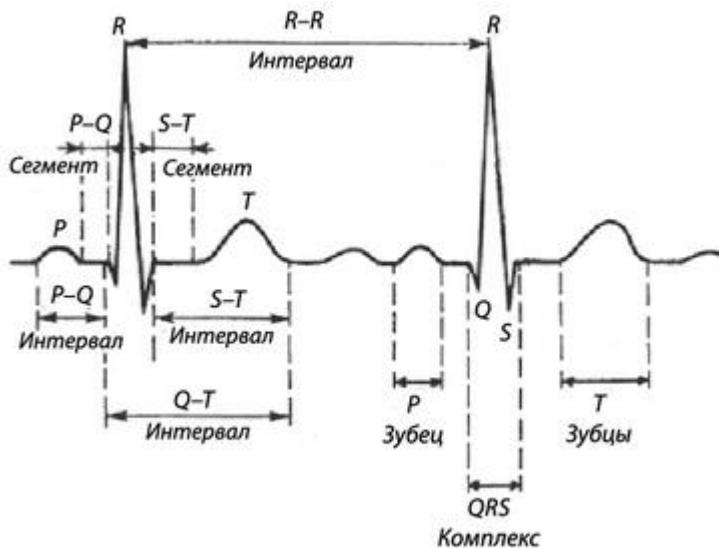


Рисунок 4 - Элементы электрокардиограммы

Появление зубцов и сегментов на нормальной электрокардиограмме происходит в следующей последовательности [5]:

- a) Зубец Р в нормальных условиях характеризует начальные события сердечного цикла и располагается на ЭКГ перед зубцами желудочкового комплекса QRS. Он отражает динамику возбуждения миокарда предсердий.
- б) Интервал PQ измеряется от начала зубца Р до начала зубца Q. Он отражает время, проходящее от начала возбуждения предсердий до начала возбуждения желудочков.

в) Далее в процесс возбуждения последовательно вовлекаются структуры миокарда желудочков. Данный процесс отражается в записи в качестве QRS комплекса. Поскольку комплекс QRS отражает процесс деполяризации мощной массы миокарда желудочков, то амплитуда зубцов QRS обычно выше, чем амплитуда зубца Р, отражающего процесс деполяризации относительно небольшой массы миокарда предсердий.

г) Вслед за комплексом QRS регистрируется сегмент ST, в этот момент запись на ЭКГ становится практически горизонтальной. В это время весь миокард правого и левого желудочков находится в состоянии возбуждения и разность потенциалов между ними практически исчезает.

д) Последующие процессы реполяризации желудочков появляются на записи в качестве зубца Т.

Анализ ЭКГ основан на оценке наличия зубцов, их последовательности, направления, формы, амплитуды, измерении длительности зубцов и интервалов, положении относительно изолинии и расчете других показателей. По результатам этой оценки делают заключение о состоянии здоровья пациента.

3.2. Разновидности искажений на электрокардиограммах

Электрокардиограмма является графиком зависимости напряжения от времени. Наряду с полезной составляющей в полученном напряжении часто присутствуют другие нежелательные изменения, которые также влияют на результирующий сигнал. Основные виды артефактов, встречающихся в электрокардиограммах, перечислены ниже.

а) Дрейф изолинии

Данный артефакт характеризуется отклонениями изолинии сигнала от горизонтального направления. Появление данного артефакта может быть обусловлено плохим контактом электродов с кожей обследуемого человека, движением пациента во время съема ЭКГ, дыханием [4].

Пример дрейфующей изолинии на записи ЭКГ изображен на рисунке 5 (а).

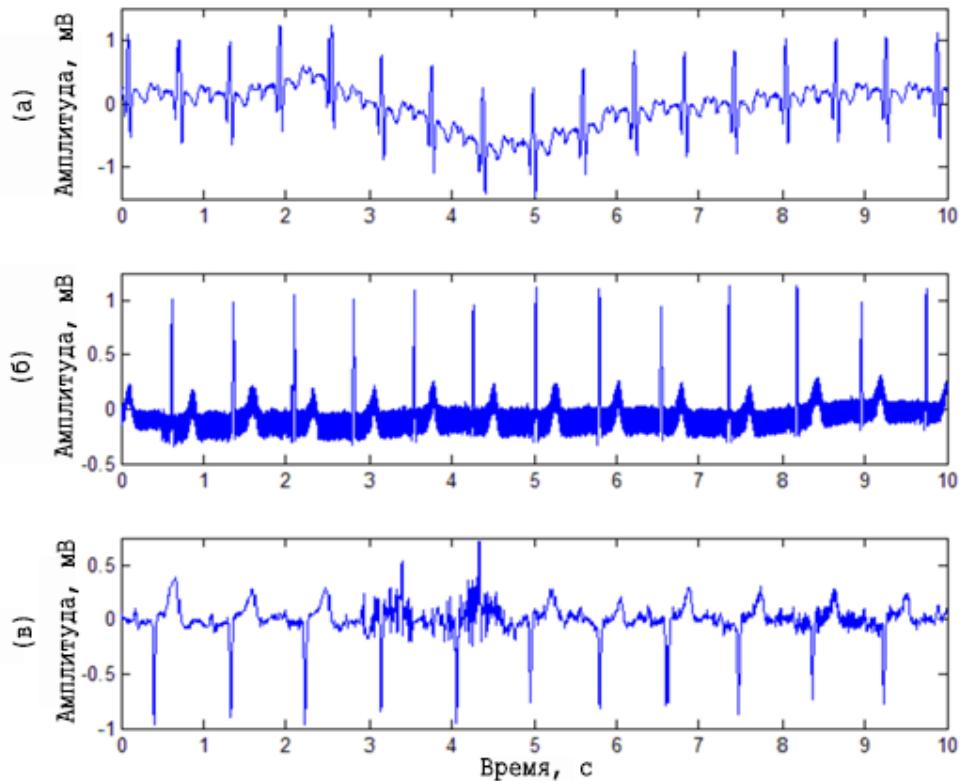


Рисунок 5 – Виды артефактов на записях ЭКГ: а) дрейф изолинии на ЭКГ; б) интерференция от линий питания аппаратурой; в) наложение шума ЭМГ на ЭКГ

Частотная составляющая изолинии в спектральной характеристике ЭКГ не превышает 0,5 Гц [6]. В связи с этим одним из базовых методов для устранения данного типа артефактов является применение различных видов линейных фильтров высоких частот. Также популярны такие методы, как интерполяция сплайнами, фильтр скользящего среднего значения, фильтр высоких частот, основанный на вейвлет-преобразовании. Некоторые из перечисленных методов подробно рассмотрены в последующих разделах.

б) Шумы от линий питания аппаратуры

Частота работы сети электропитания принимает значения 50 Гц или 60 Гц в зависимости от страны. Приборы, подключенные к системе электрического питания, излучают электромагнитные поля, из-за чего образуются дополнительные источники шума на записях ЭКГ [7]. Сигнал, зашумленный в

результате синусоидальной интерференции на соответствующей сетевой частоте и её гармониках, показан на рисунке 5 (б).

Такой узкополосный шум сильно препятствует эффективному анализу ЭКГ записей, так как он практически перекрывает низкочастотные волны на электрокардиограмме, такие как Р и Т. В связи с этим принимаются различные меры предосторожности, чтобы устранить данную проблему еще на этапе снятия ЭКГ: например, экранирование кабелей и проводов аппаратуры. Однако, несмотря на это, иногда необходима дополнительная обработка сигнала уже после завершения записи сигнала.

в) Наложение электромиограммы

Если электрод ЭКГ размещен над мышцей, то активация этой мышцы может вызвать наложение электромиограммы (ЭМГ) на ЭКГ [8]. Пример наложения сигнала, возникающего из-за мышечного трепора, показан на рисунке 5 (в).

Шум, вызванный мышечными сокращениями, нельзя удалить с помощью узкополосных фильтров. Частотные компоненты шума данного типа перекрывают частотные компоненты QRS комплекса, что усложняет задачу их исключения.

г) Артефакты, вызванные движением электродов

В течение работы прибора электроды могут смещаться под воздействием вибраций. Их смещения приводят к растяжению кожного покрова в прилегающих участках, что приводит к изменению импеданса между кожей и поверхностью электродов.

Частотная характеристика артефактов данного типа варьируется в пределах от 1 Гц до 10 Гц.

На записях ЭКГ данный тип артефактов проявляется в виде участков с большой амплитудой, которые могут быть ошибочно приняты за зубцы QRS комплекса, а также в виде дрейфа изолинии. Пример записи ЭКГ, зашумленной артефактами, вызванными движением электродов, показан на рисунке 6.

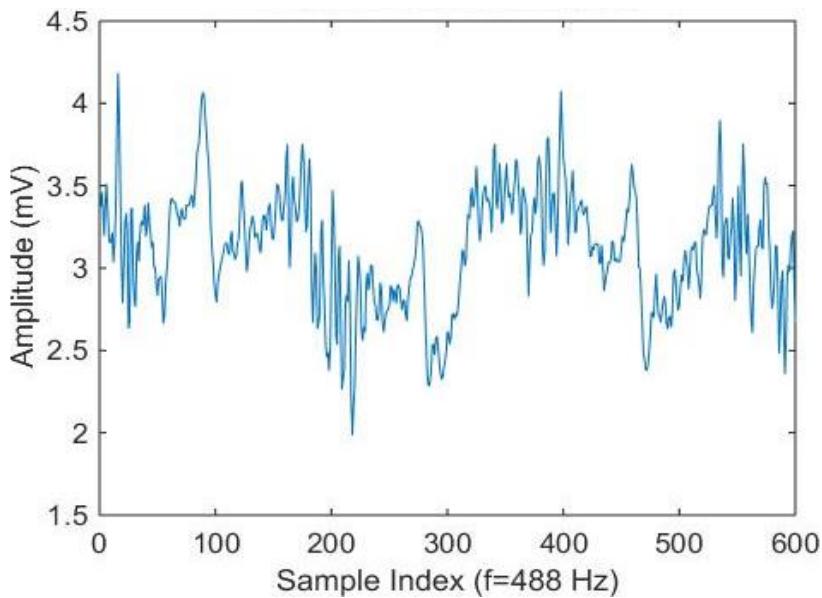


Рисунок 6 - ЭКГ, зашумленная артефактами, вызванными движением электродов

3.3. Линейные цифровые фильтры для преобразования сигналов

Для изменения частотного спектра сигнала применяются различные типы фильтрации. Для подавления или выделения определенных диапазонов частот в цифровых сигналах часто используются линейные цифровые фильтры.

Линейные фильтры представляют собой динамические системы, применяющие некий линейный оператор ко входному сигналу для выделения или подавления определенных частот сигнала.

По виду амплитудно-частотной характеристики (АЧХ) фильтры разделяются на: фильтры нижних частот (ФНЧ), фильтры верхних частот (ФВЧ), полосовые фильтры и режекторные. При этом полосовой фильтр может быть получен путем последовательного соединения фильтров высоких и низких частот.

На рисунке 7 изображены амплитудно-частотные характеристики распространенных линейных фильтров, таких как фильтр Чебышева, фильтр Баттервортса, фильтр Бесселя и RC-фильтр.

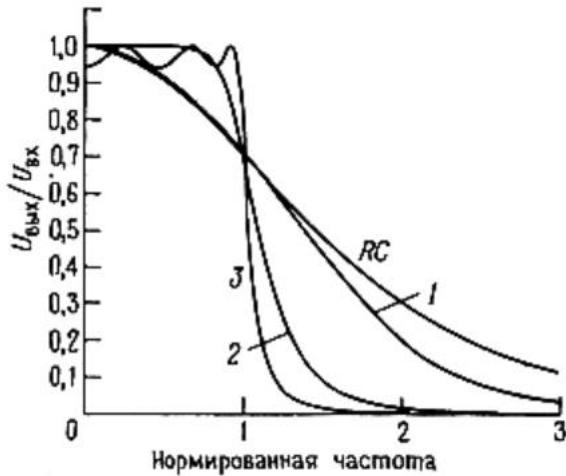


Рисунок 7 - Сравнение АЧХ наиболее популярных линейных фильтров:
 (1) фильтр Бесселя; (2) фильтр Баттервортса; (3) фильтр Чебышева;
 (RC) RC-фильтр

По рисунку 7 видно, что фильтр Чебышева обладает наиболее крутым переходом от полосы пропускания к полосе подавления. Однако в полосе пропускания его АЧХ не монотонна, а имеет волнообразный характер с постоянной амплитудой [9]. Можно заметить, что наиболее плоскую характеристику в полосе пропускания среди остальных линейных фильтров обеспечивает фильтр Баттервортса, который при этом обладает довольно резким переходом на частоте среза по отношению к более пологим спадам амплитуды фильтра Бесселя и RC-фильтра.

На рисунке 8 показаны АЧХ фильтра Баттервортса различных порядков. По графику видно, что с увеличением порядка фильтра увеличивается крутизна перехода от полосы пропускания к полосе подавления, коэффициент передачи в полосе пропускания все в большей степени приближается к единице, переходная область все в большей степени сужается, а в полосе задерживания функция передачи все ближе и ближе подходит к нулю. При $n \rightarrow \infty$ АЧХ фильтра Баттервортса приближается к идеальной.

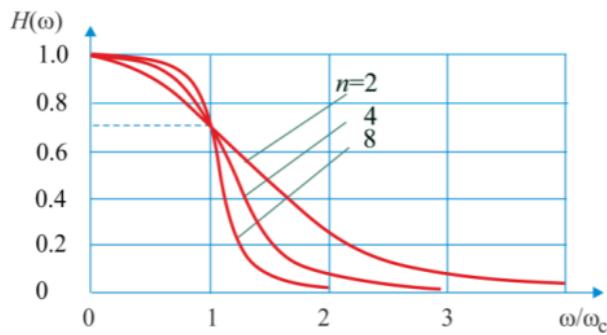


Рисунок 8 - АЧХ фильтров Баттервортта различных порядков

3.4. Частотно-временные преобразования сигналов

Подавляющее большинство сигналов, встречающихся на практике, представлены во временной области, то есть сигнал является функцией времени. Амплитудно-временное представление сигнала в большинстве случаев не является наилучшим, так как наиболее значимая информация скрыта в частотном представлении. Электрокардиографический сигнал не является исключением. Типичный вид ЭКГ хорошо известен любому кардиологу, и любое значительное отклонение от стандартного вида сигнала рассматривается как патология. Но патология не всегда проявляется в значительном отклонении, поэтому в последних моделях электрокардиографов используется частотное представление сигнала. Для получения частотной информации об исходном сигнале нужно использовать частотно-временное преобразование. Наиболее популярными видами частотно-временных преобразований являются различные преобразования Фурье и вейвлет-преобразования.

3.4.1. Непрерывное преобразование Фурье

Важнейшей характеристикой исходного сигнала является его преобразование Фурье. Если исходный сигнал определен функцией $X(t)$, заданной на всей оси вещественных чисел, то его преобразование Фурье $F(\omega)$ задается формулой (1):

$$F(\omega) = \int_{-\infty}^{+\infty} X(t) e^{-i\omega t} dt. \quad (1)$$

Формула (1) является прямым преобразованием Фурье для непериодических функций. Из формулы (1) видно, что преобразование является комплексной величиной, даже если сигнал действительный. При этом действительная часть полученного преобразования отвечает за амплитудный спектр, а мнимая – за фазовый. Математический смысл преобразования Фурье состоит в представлении функции $X(t)$ в виде бесконечной суммы синусоид вида $F(\omega) \cdot \sin(\omega t)$ [10]. Также можно сказать, что преобразование Фурье представляет собой проекцию исходного сигнала на базис пространства, выраженный в виде ортогональной системы комплексных экспоненциальных функций. Функция $F(\omega)$ или ее модуль трактуются как интенсивность исходного сигнала на круговой частоте ω , измеряющейся в радианах в секунду.

Круговая частота связана с линейной частотой ν , единицами измерения которой являются значения в герцах [Гц, кГц, МГц], формулой (2):

$$\omega = 2\pi\nu. \quad (2)$$

Периодический сигнал $X(t)$, непрерывный во времени t , представляет собой бесконечную сумму фрагментов, повторяющихся с периодом T . Для периодических функций можно модифицировать формулу (1) и провести интегрирование по периоду T [11]. Спектр Фурье отдельного фрагмента при этом будет непрерывным, а спектр всего сигнала будет дискретным. Прямое преобразование Фурье для периодических функций находится по формуле (3):

$$F(k) = \frac{1}{T} \int_0^T X(t) e^{-i\omega kt} dt, \quad (3)$$

где k – количество периодов, $k \in (-\infty; \infty)$.

Формирование во времени периодической последовательности одиночных импульсов приводит к равномерной дискретизации непрерывного спектра одиночного импульса с интервалом частот, равным $\Delta\omega = \frac{2\pi}{T}$ [11].

Обратное преобразование Фурье для периодических функций рассчитывается по формуле (4):

$$X(t) = \sum_{k=-\infty}^{\infty} e^{-i\omega kt} F(k). \quad (4)$$

В качестве примера действия преобразования Фурье можно рассмотреть рисунок 9, приведенный для следующего модельного сигнала:

$$y(x) = 1 \cdot \sin(2 \cdot \pi \cdot 0.05 \cdot x) + 0.5 \cdot \sin(2 \cdot \pi \cdot 0.1 \cdot x) + 0.1 \cdot \sin(2 \cdot \pi \cdot 0.5 \cdot x).$$

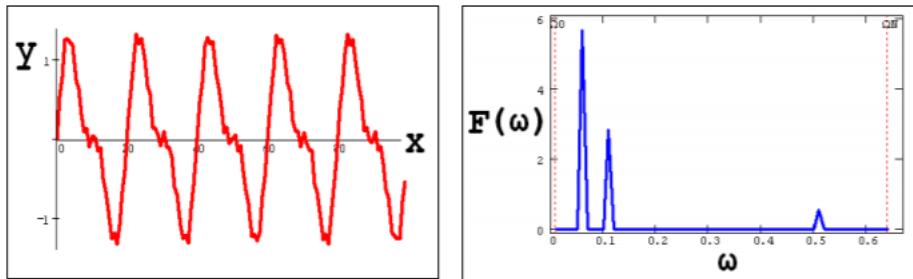


Рисунок 9 -Сигнал и модуль его спектра Фурье

3.4.2. Дискретное преобразование Фурье

Так как экспериментальные сигналы представляют собой временные ряды, то в таком случае время рассчитывается по формуле (5):

$$t = n\Delta t, \quad (5)$$

где n - номер отсчета, Δt - интервал дискретизации.

Следовательно, нужно использовать дискретное преобразование Фурье. Прямое дискретное преобразование Фурье получается из формулы (3) заменой операции интегрирования по периоду на операцию суммирования по количеству отсчетов в периоде:

$$F(k) = \sum_{n=0}^{N-1} X(n) e^{-\frac{i \cdot 2\pi \cdot kn}{N}}, \quad (6)$$

где N – количество дискретных отсчетов в периоде,

$$k \in (0; N - 1).$$

Спектр сигнала при этом является периодическим (потому что исходный сигнал дискретный), и является дискретным (потому что исходный сигнал периодический).

В таком случае обратное дискретное преобразование Фурье рассчитывается по формуле (7):

$$X(n) = \frac{1}{N} \sum_{k=0}^{N-1} F(k) e^{\frac{i \cdot 2\pi \cdot kn}{N}}, \quad (7)$$

где $n \in (0; N - 1)$.

С позиций анализа произвольных сигналов и функций в частотной области и точного восстановления после преобразований можно отметить ряд недостатков разложения сигналов в ряды Фурье. Основные из них перечислены ниже [12].

а) Так как в частотной области происходит «размазывание» особенностей сигналов (разрывов, ступенек, пиков и т.п.) по всему частотному диапазону спектра, то это приводит к ограничению информативности анализа нестационарных сигналов и практически к полному отсутствию возможностей анализа их особенностей.

б) Гармонические базисные функции разложения не способны отображать перепады сигналов с бесконечной крутизной типа прямоугольных импульсов, так как для этого требуется бесконечно большое число членов ряда.

в) Преобразование Фурье отображает глобальные сведения о частотах исследуемого сигнала и не дает представления о локальных свойствах сигнала при быстрых временных изменениях его спектрального состава. Так, например, преобразование Фурье не различает стационарный сигнал с суммой двух синусоид от нестационарного сигнала с двумя последовательно следующими синусоидами с теми же частотами, потому как спектральные коэффициенты вычисляются интегрированием по всему интервалу задания сигнала. Преобразование Фурье не имеет возможности анализировать частотные характеристики сигнала в произвольные моменты времени.

г) Кроме того, известно, что частота сигнала обратно пропорциональна его продолжительности. Поэтому для получения высокочастотной информации с хорошей точностью важно извлекать ее из относительно малых временных интервалов, а не из всего сигнала. Для

получения низкочастотной информации рассматриваются относительно широкие временные интервалы сигнала.

Данные недостатки стимулировали развитие вейвлет-преобразований.

3.4.3. Непрерывное вейвлет-преобразование

Главное достоинство вейвлет-преобразования заключается в ключевом свойстве базисных вейвлет-функций – они локализованы как в пространственной, так и в частотной областях [10]. Эта особенность является и главным отличием от базисных функций, используемых в преобразованиях Фурье, так как последние предельно локализованы в частотной области и распределены по всему временному интервалу.

Также явным преимуществом вейвлет-преобразования относительно преобразования Фурье является возможность представления сигнала не только в низкочастотных, но и в высокочастотных областях [13].

При проведении вейвлет-преобразования данные раскладываются не по тригонометрическим функциям, как в случае преобразования Фурье, а по особым вейвлет-функциям $\psi(t) \in L^2(R)$. Сравнение форм тригонометрической функции и вейвлет-функции приведено на рисунке 10.

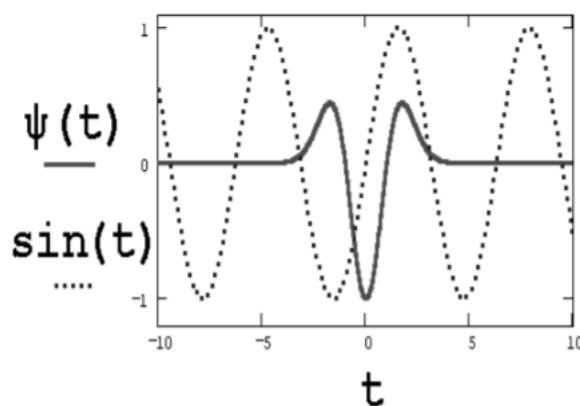


Рисунок 10 - Сравнение синусоиды и вейвлет-функции

Вейвлет-функции $\psi(t)$ обладают следующими свойствами [14]:

- Локализация

Вейвлет должен быть локализован и по времени, и по частоте. На рисунке 10 изображен пример вейвлет-функции, называемой «мексиканской шляпой». По рисунку видно, что данная функция локализована в некоторой ограниченной области своего аргумента, а вдали от нее равна 0. Благодаря такой локализации каждый коэффициент разложения описывает лишь фрагмент сигнала, а все коэффициенты в сумме уже представляют сигнал целиком, в то время как каждый коэффициент разложения Фурье содержит информацию о структуре сигнала целиком.

б) Нулевое среднее значение

$$\int_{-\infty}^{+\infty} \psi(t) dt = 0. \quad (8)$$

в) Ограниченнность

Вейвлет должен обладать конечной энергией.

$$\int_{-\infty}^{+\infty} |\psi(t)|^2 dt < \infty. \quad (9)$$

Характерным признаком базиса вейвлет-преобразования является его самоподобие [14]. Все вейвлеты данного семейства $\psi_{ab}(t)$ имеют то же число осцилляций, что и базисный вейвлет $\psi(t)$, поскольку получены из него посредством масштабных преобразований и сдвигов. Получение семейства $\psi_{ab}(t)$ вейвлетов по материнскому вейвлету $\psi(t)$, описывается формулой (10):

$$\psi_{ab}(t) = \frac{1}{\sqrt{a}} \psi\left(\frac{t-b}{a}\right), \quad (10)$$

где a – масштабный коэффициент (параметр растяжения-сжатия),

b - времененная локализация (сдвиг по времени).

Операция сдвига по временной оси используется для перекрытия локальной функцией вейвлета всей временной оси пространства $L^2(R)$. Аналогично операция временного масштабирования используется для перекрытия всего частотного диапазона пространства.

Следовательно, вейвлет-спектр также имеет не один аргумент, а два - a и b , о которых упоминалось ранее в формуле (10). Так как b описывает локализацию вейвлета, то размерность этого коэффициента совпадает с

размерностью t . В пространстве переменных a и b вейвлет-спектр имеет вид двумерной поверхности.

Согласно определению, вейвлет-спектр представляет собой интеграл по произведению вейвлет-функции $\psi_{ab}(t)$ и исходного сигнала $X(t)$ [10]:

$$W(a, b) = \frac{1}{\sqrt{a}} \int_{-\infty}^{+\infty} X(t) \psi\left(\frac{t-b}{a}\right) dt. \quad (11)$$

Формула (11) получила название прямого непрерывного вейвлет-преобразования.

Обратное непрерывное вейвлет-преобразования при этом описывается формулой (12):

$$X(t) = \frac{1}{C_\psi} \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} \frac{1}{a^2} W(a, b) \psi_{ab}(t) da db, \quad (12)$$

где C_ψ – нормирующий коэффициент.

$$C_\psi = \int_{-\infty}^{+\infty} \frac{|F(\omega)|^2}{|\omega|} d\omega < \infty, \quad (13)$$

где $F(\omega)$ – фурье-преобразование вейвлета $\psi(t)$. Для ортонормированных вейвлетов $C_\psi = 1$.

В качестве примера, иллюстрирующего непрерывное вейвлет-преобразование, приведены рисунки 11-13. На рисунке 11 показан модельный сигнал, а рисунки 12 и 13 отображают его вейвлет-спектр в виде поверхности в пространстве и изолиний на плоскости соответственно.

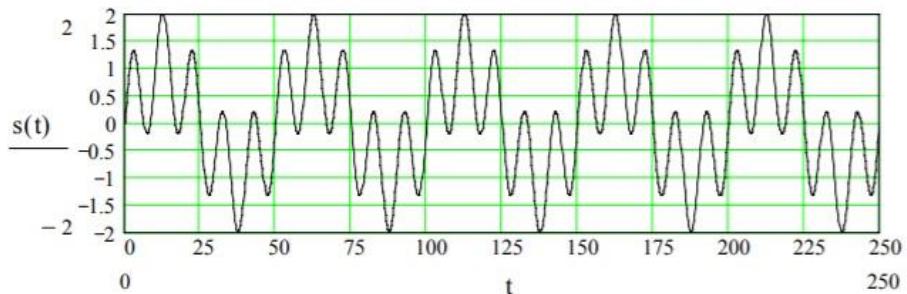


Рисунок 11 - Модельный сигнал

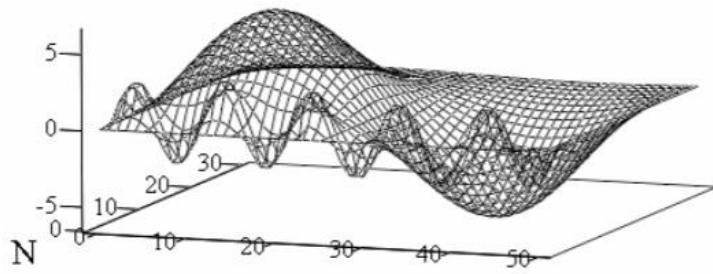


Рисунок 12 - Вейвлет-спектр в виде поверхности в пространстве

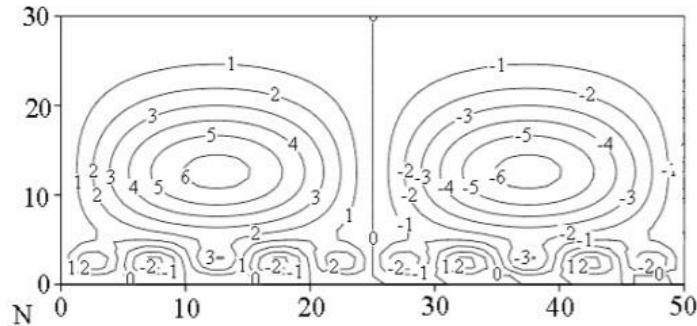


Рисунок 13 - Вейвлет-спектр в виде изолиний на плоскости

3.4.4. Диадное вейвлет-преобразование

При непрерывном изменении параметров a и b для расчета вейвлет-спектра необходимы большие вычислительные затраты. Множество функций $\psi_{ab}(t)$ избыточно. Необходима дискретизация этих параметров при сохранении возможности восстановления сигнала из его преобразования. Дискретизация, как правило, осуществляется через степени двойки [15]:

$$a = 2^m, \quad (14)$$

$$b = k \cdot 2^m, \quad (15)$$

$$\psi_{mk}(t) = \frac{1}{\sqrt{a}} \psi\left(\frac{t-b}{a}\right) = \frac{1}{\sqrt{2^m}} \psi(2^{-m}t - k), \quad (16)$$

где m – параметр масштаба, $m \in \mathbb{Z}$,

k – параметр сдвига, $k \in \mathbb{Z}$.

В этом случае плоскость (a, b) превращается в соответствующую сетку (m, k) .

Рассмотренная дискретизация наиболее распространена. Сетка дискретизации называется диадной и соответствующее преобразование – диадным вейвлет-преобразованием. Диадное преобразование раскладывает сигнал на взаимно ортогональный набор вейвлетов, что является основным отличием от непрерывного вейвлет-преобразования. Вейвлет-коэффициенты прямого диадного вейвлет-преобразование находятся по формуле (17):

$$C_{mk} = \int_{-\infty}^{\infty} X(t) \psi_{mk}(t) dt. \quad (17)$$

Статьи, касающиеся практического использования вейвлет-преобразования, содержат в основной своей массе результаты компьютерных расчетов, в которых использовано дискретное вейвлет-преобразование (ДВП или англ. DWT). При этом не только параметры a и b , но и сигналы также дискретизируются во времени. Однако формулы дискретного ВП нельзя получить простой дискретизацией соответствующих формул непрерывного времени.

Для выводения формул дискретного вейвлет-преобразования (ДВП) необходимо ввести понятие кратномасштабного анализа, о котором пойдет речь в разделе 3.4.5.

3.4.5. Быстрое вейвлет-преобразование

При исследовании сигналов полезно их представление в виде совокупности последовательных приближений грубой (аппроксимирующей) $A_m(t)$ и уточненной (детализирующей) $D_m(t)$ составляющих [15] с последующим их уточнением итерационным методом:

$$X(t) = A_m(t) + \sum_{j=1}^m D_j(t). \quad (18)$$

Каждый шаг уточнения соответствует определенному масштабу a^m (т.е. уровню m) анализа (декомпозиции) и синтеза (реконструкции) сигнала. В таком случае реконструкция сигнала, разложенного до некоторого уровня m , вычисляется по формуле (19):

$$X(t) = \sum_{k=-\infty}^{\infty} a_{mk} \phi_{mk}(t) + \sum_{j=1}^m \sum_{k=-\infty}^{\infty} d_{jk} \psi_{jk}(t), \quad (19)$$

где a_{mk} – аппроксимирующие коэффициенты,

d_{jk} – детализирующие коэффициенты.

Такое представление каждой составляющей сигнала вейвлетами можно рассматривать как во временной, так и в частотной областях. В этом суть кратномасштабного анализа (КМА), схема которого рассмотрена на рисунке 14.

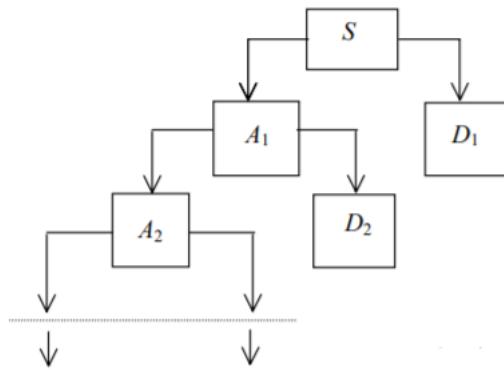


Рисунок 14 - Пример кратномасштабного анализа

На рисунке 14 используются следующие обозначения: A_m – грубое представление сигнала на каждом уровне разложения m , D_m – детализирующая составляющая, определяющая локальные особенности и свойства сигнала.

Для ортогональных вейвлетов существует быстрое вейвлет-преобразование (БВП) – итерационная процедура, позволяющая вычислить вейвлет-коэффициенты C_{mk} . Самый ранний и наиболее известный алгоритм БВП – алгоритм Малла (пирамидальный). Эффективность БВП достигается за счет того, что в данном алгоритме расчет коэффициентов не зависит от базисных вейвлет-функций.

Для вычисления коэффициентов a_{mk} и d_{mk} уровня разложения m в БВП используются формулы (27) и (28). Вывод этих формул показан далее.

Пусть имеется непрерывный сигнал $X(t)$, тогда дискретный сигнал может быть интерпретирован как последовательность коэффициентов a_k при масштабирующих функциях, по которым раскладывается $X(t)$:

$$X(t) = A_0(t) = \sum_k a_{0k} \phi_{0k}(t), \quad (20)$$

$$a_{0k} = a_k = \langle X(t), \phi_{0k}(t) \rangle. \quad (21)$$

Согласно концепции кратномасштабного анализа функция $X(t)$ декомпозируется на функции $A_1(t)$ и $D_1(t)$:

$$X(t) = A_1(t) + D_1(t) = \sum_k a_{1k} \phi_{1k}(t) + \sum_k d_{1k} \psi_{1k}(t). \quad (22)$$

Следовательно, получены новые последовательности a_{1k} и d_{1k} , длины которых в два раза меньше длины a_{0k} . Далее процесс декомпозиции может быть продолжен по $A_1(t)$ и так далее до максимального уровня разложения [15].

Из определения кратномасштабного анализа следует, что все функции в пространстве V_m могут быть представлены как линейная комбинация масштабирующих функций. Так как $\varphi(t) = \varphi_{00}(t) \in V_0 \subset V_1$, то можно записать следующее равенство, называемое в литературе масштабирующим уравнением:

$$\varphi_{00}(t) = 2^{1/2} \sum_l h_l \varphi_{-1l}(t) = 2 \sum_l h_l \varphi(2t - l), \quad (23)$$

где h_l – некоторая последовательность,

l может принимать $(2n - 1)$ значений, n – порядок вейвлета.

Базисную функцию $\psi(t)$ можно выразить из условия ортогональности базисных функций $\psi(t)$ и $\varphi(t)$ с помощью уравнения (24):

$$\psi(t) = 2 \sum_l (-1)^l h_{1-l} \varphi(2t - k) = 2 \sum_l g_l \varphi(2t - k). \quad (24)$$

Последовательности h_l и g_l находятся следующим образом:

$$h_l = \langle \varphi(t), \varphi(2t - l) \rangle, \quad (25)$$

$$g_l = (-1)^l h_{2n-1-l}. \quad (26)$$

Из (23) и (24) следует, что при переходе от текущего масштаба m к следующему $m + 1$ число вейвлет-коэффициентов уменьшается в два раза и они определяются по рекуррентным соотношениям:

$$a_{mk} = \langle X(t), \varphi_{mk}(t) \rangle = \sum_l h_{l-2k} \langle \varphi(t), \varphi_{m-1,l}(t) \rangle = \sum_l h_{l-2k} a_{l,m-1}, \quad (27)$$

$$d_{mk} = \langle X(t), \psi_{mk}(t) \rangle = \sum_l g_{l-2k} \langle \varphi(t), \varphi_{m-1,l}(t) \rangle = \sum_l g_{l-2k} a_{l,m-1}. \quad (28)$$

При восстановлении (реконструкции) сигнала по его вейвлет-коэффициентам процесс идет от крупных масштабов к мелким и на каждом шаге описывается выражением:

$$a_{m-1,k} = \sum_l (h_{k-2l}a_{ml} + g_{k-2l}d_{ml}). \quad (29)$$

Таким образом, вейвлет-коэффициенты дискретного ВП могут быть найдены с помощью быстрого вейвлет-преобразования. Кроме того, БВП может использоваться для простого и быстрого удаления шума из зашумлённого сигнала. Если взять только ограниченное число наиболее высоких коэффициентов спектра дискретного вейвлет-преобразования и провести обратное вейвлет-преобразование с тем же базисом, можно получить сигнал, очищенный от шума [15].

3.5. Сравнительный анализ различных методов фильтрации на реальных данных

Одним из популярных способов удаления шумов из сигнала является применение линейных фильтров, которые были подробно описаны в разделе 3.3. В том же разделе были обоснованы преимущества фильтра Баттервортса, поэтому среди остальных перечисленных линейных фильтров был выбран именно он. Далее будет показано его применение на реальных тестовых данных.

Входными данными для исследования послужили записи ЭКГ из набора данных ECG-ID Database. Этот набор данных включает записи ЭКГ, содержащие как высокочастотные, так и низкочастотные шумы. Записи сигналов были взяты с интернет-портала PhysioNet. Данный ресурс был основан в 1999 году под эгидой Национальных институтов здравоохранения США (анг. National Institutes of Health (NIH)) и содержит большой архив цифровых записей физиологических сигналов (PhysioBank). Пример сигнала из ECG-ID Database изображен на рисунке 15.

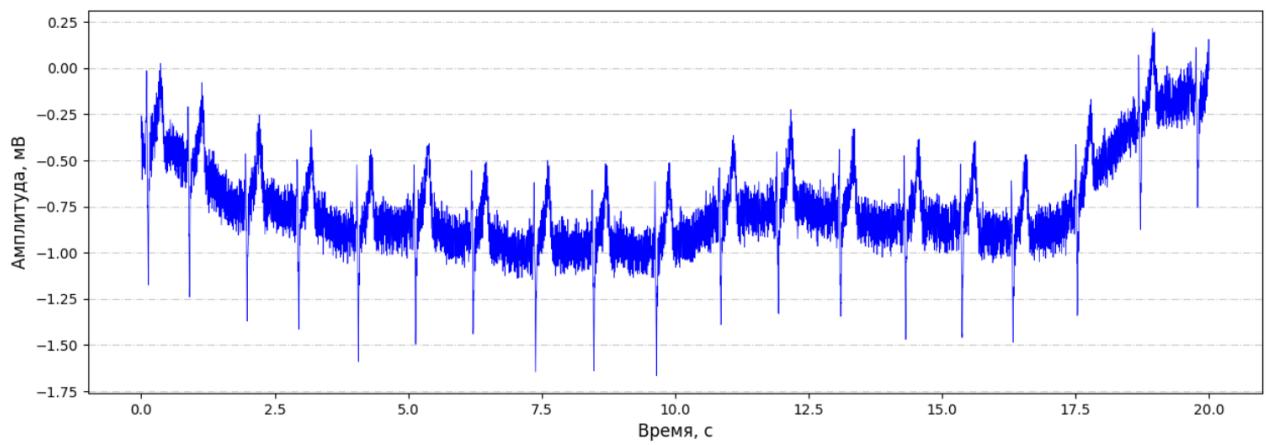


Рисунок 15 - Исходный сигнал из набора данных ECG-ID Database

По рисунку видно, что в сигнале присутствуют низкочастотные шумы, являющиеся причиной дрейфа изолинии. Для их удаления может быть использован фильтр высоких частот Баттервортса. Фильтры высоких частот пропускают высокие частоты входного сигнала и подавляют частоты, находящиеся ниже частоты среза. В то же время в исходном сигнале на рисунке 15 присутствуют и высокочастотные шумы, для удаления которых требуется применение низкочастотного фильтра Баттервортса. Последовательное применение ФВЧ и ФНЧ можно заменить применением полосового фильтра, который пропускает только частоты, находящиеся в определенном диапазоне.

Частотный спектр неочищенной электрокардиограммы лежит в диапазоне от 0 Гц до 100 Гц. Данный спектр складывается как из частот полезной составляющей сигнала, так и из частот нежелательных артефактов. Частоты главных компонент сигнала распределены в гораздо меньшем диапазоне – от 0.5 Гц до 45 Гц, причем 90% энергии сигнала сосредоточено в интервале 0.25 – 35 Гц [16]. В связи с этим к исходному сигналу был применен полосовой фильтр Баттервортса четвертого порядка с диапазоном частот от 0.5 Гц до 35 Гц.

На рисунке 16 (а) показан исходный сигнал, а на рисунке 16 (б) - сигнал после помехоподавления с помощью полосового фильтра Баттервортса.

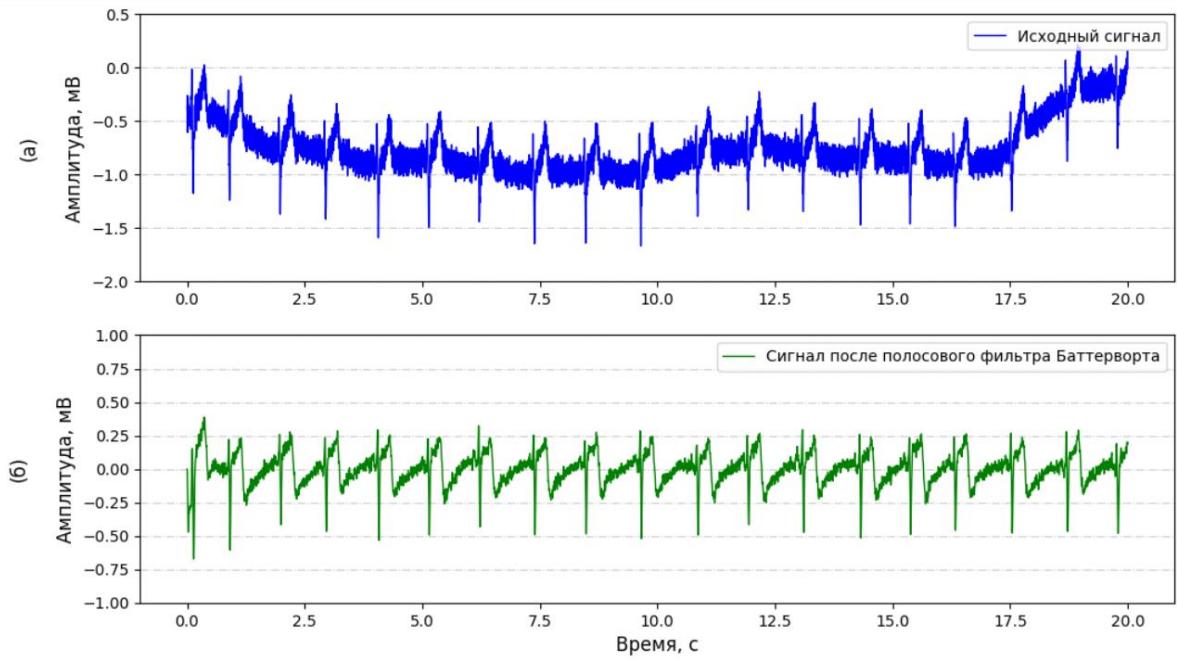


Рисунок 16 – Влияние полосового фильтра Баттервортта на сигнал: (а) исходный сигнал; (б) отфильтрованный сигнал

После фильтрации изолиния сигнала стала ровнее. Видно, что график сигнала после помехоподавления стал более гладким. Однако его интервал ST оказался деформированным.

Существенными недостатками линейных фильтров являются их способность изменять амплитуды и длительность зубцов сигнала, а также смещение интервалов ЭКГ.

В статье [17] для удаления дрейфа изолинии ЭКГ применяется фильтр скользящего среднего значения. В связи с этим был предложен способ помехоподавления в сигнале, состоящий из последовательного применения низкочастотного фильтра Баттервортта и фильтра скользящего среднего значения. Результаты данного алгоритма фильтрации показаны на рисунке 17. Графики 17 (а) и 17 (в) специально представлены в меньшем масштабе для наглядной демонстрации выравнивания изолинии.

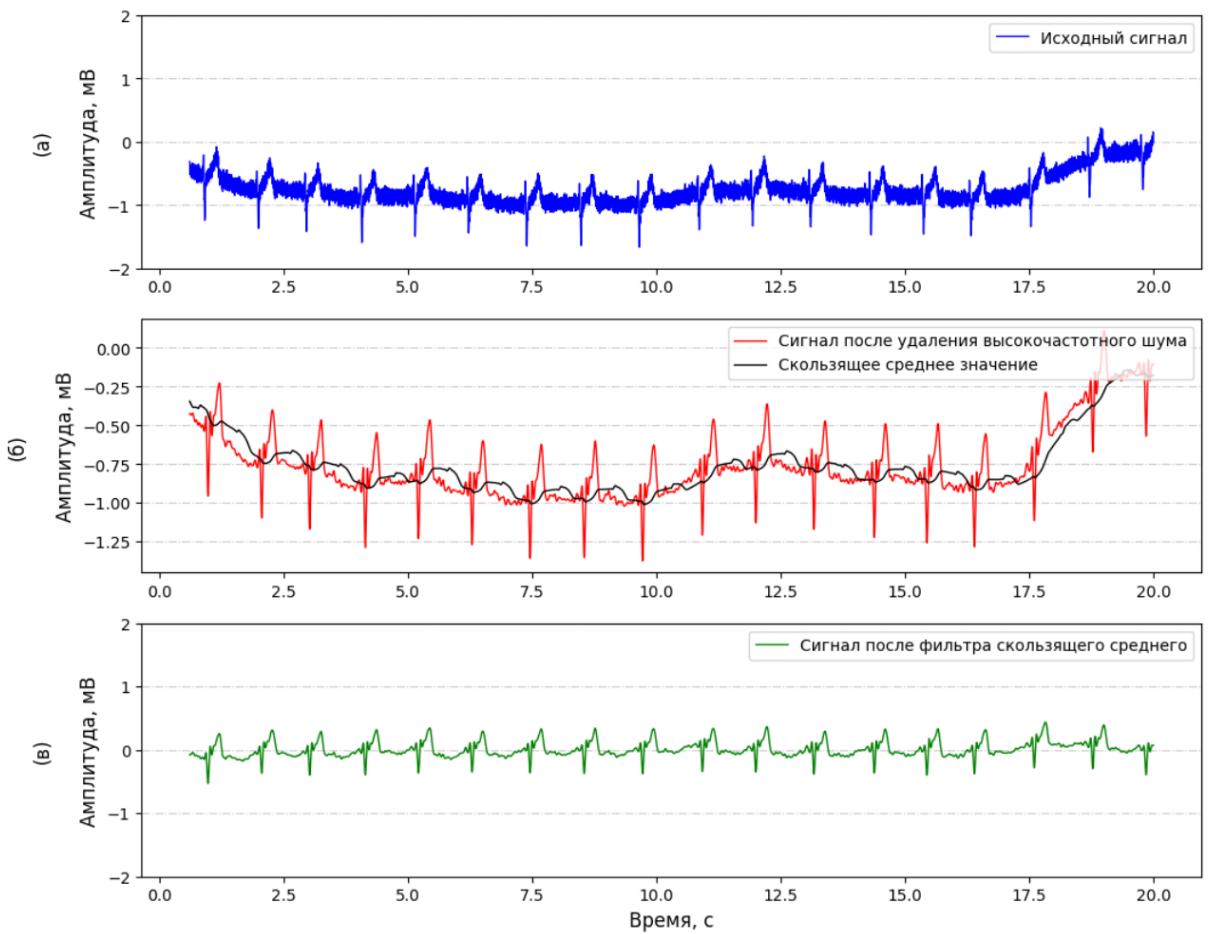


Рисунок 17 – Влияние на сигнал последовательного применения низкочастотного фильтра и фильтра скользящего среднего: (а) исходный сигнал; (б) сигнал после удаления высокочастотных шумов; (в) сигнал после удаления высокочастотного шума и дрейфа изолинии

Такой способ гораздо лучше сохраняет структуру ЭКГ в отличие от полосового фильтра Баттервортса, однако фильтр скользящего среднего значения имеет существенный недостаток – результат его применения сильно зависит от размера окна.

Учитывая недостатки методов, рассмотренных ранее, было решено применять для удаления помех последовательную комбинацию низкочастотного фильтра Баттервортса и фильтра на основе быстрого вейвлет-преобразования. Результат применения такого алгоритма показан на рисунке 18. Фильтр на основе БВП удобен для выравнивания изолинии тем, что автоматически раскладывает сигнал на грубую и детализирующую составляющие, не требуя при этом настраиваемых параметров.

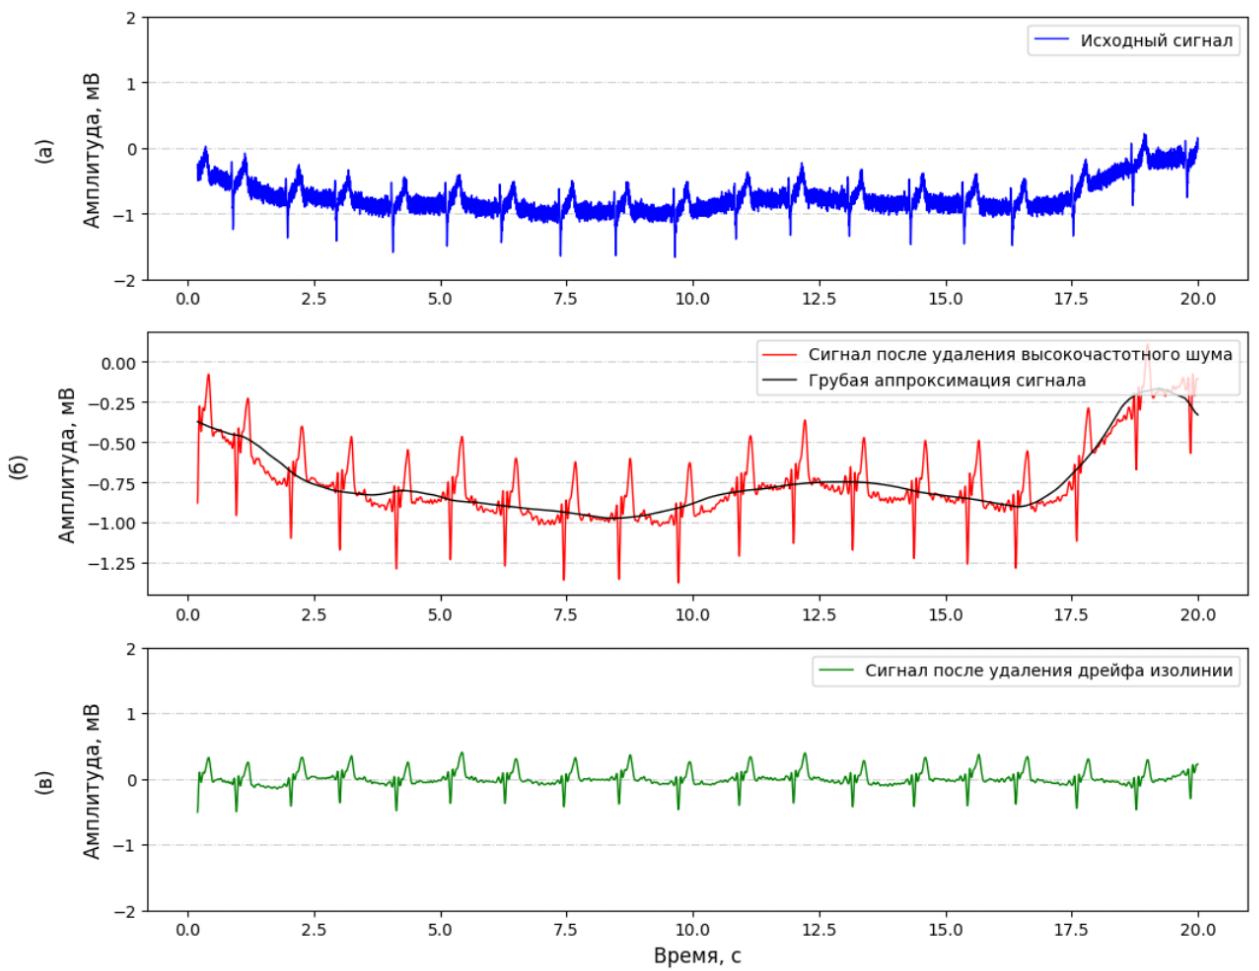


Рисунок 18 – Влияние на сигнал последовательного применения низкочастотного фильтра и фильтра на основе БВП: (а) исходный сигнал; (б) сигнал после удаления высокочастотных шумов; (в) сигнал после удаления высокочастотного шума и дрейфа изолинии

4. Этап обнаружения аномалий

4.1. Рекуррентные нейронные сети

Из пункта 2 данной работы следует, что задача поиска аномалий в биомедицинских сигналах сводится к обнаружению контекстуальных аномалий, которые могут быть как точечными, так и коллективными. Следовательно, структура обычной нейронной сети с фиксированным числом входов, которые воспринимаются как независимые, в данном случае оказывается несообразной. Так как во входной последовательности данных наблюдается некая закономерность, которую нельзя игнорировать, должна быть выбрана архитектура нейронной сети, способная учитывать присутствующие закономерности. Для того чтобы отразить такую временную зависимость в данных, часто используются рекуррентные нейронные сети (анг. Recurrent Neural Networks, RNN) [18].

Главная идея рекуррентных нейронных сетей состоит в том, что связи между нейронами в них могут идти не только от нижнего слоя к верхнему, но и от нейрона к «самому себе», точнее, к предыдущему значению самого этого нейрона или других нейронов того же слоя. Именно это позволяет отразить зависимость переменной от своих значений в разные моменты времени: нейрон обучается использовать не только текущий вход и то, что с ним сделали нейроны предыдущих уровней, но и то, что происходило с ним самим и, возможно, другими нейронами на предыдущих входах.

Схематически эта идея изображена на рисунке 19. На схеме фрагмент нейронной сети A принимает входное значение x_t и возвращает значение h_t . Наличие обратной связи позволяет передавать информацию от одного шага сети к другому. По схеме видно, что рекуррентную сеть в развертке можно рассматривать, как несколько копий одной и той же сети, каждая из которых передает информацию последующей копии.

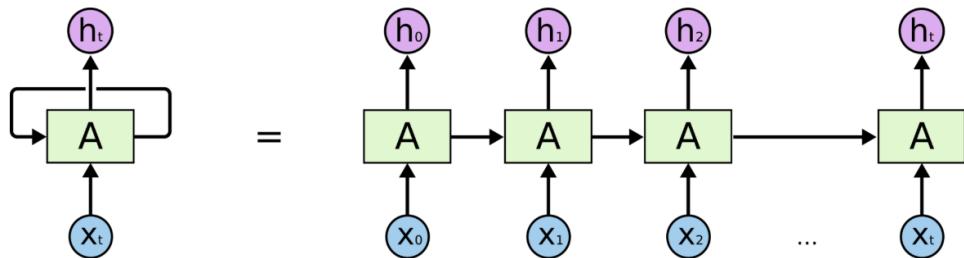


Рисунок 19 - Рекуррентная нейронная сеть в развертке

4.2. Архитектура рекуррентной сети с долгой краткосрочной памятью

В обычных рекуррентных сетях в процессе обучения методом обратного распространения ошибки формула для вычисления градиентного сигнала усложняется многократным повторением одних и тех же весов. Это означает, что величины весов в матрице переходов оказывают сильное влияние на процесс обучения. Если веса в матрице слишком малы, это может привести к ситуации, называемой «исчезающими градиентами» (анг. vanishing gradients), когда градиентный сигнал становится настолько мал, что процесс обучения либо сильно замедляется, либо останавливается совсем. И наоборот, слишком большие значения весов приводят к ситуации «взрывающихся градиентов» (анг. exploding gradients), когда градиентный сигнал настолько велик, что процесс обучения расходится [19].

В связи с перечисленными проблемами обыкновенная рекуррентная нейронная сеть теряет способность связывать информацию по мере роста расстояния между точкой появления информации и точкой ее применения. Чтобы исключить подобный эффект была разработана рекуррентная нейронная сеть с долгой краткосрочной памятью (анг. Long Short-Term Memory Network, или LSTM Network), которая вводит новую структуру под названием «ячейка памяти».

Структура LSTM-сети в развертке, как и структура любой другой рекуррентной нейронной сети, представляет собой цепочку повторяющихся модулей нейронной сети. В обычной RNN структура одного такого модуля состоит из одного слоя с некой функцией активации. Структура LSTM-модуля состоит из четырех слоев [20]. Сравнение модулей классической рекуррентной сети и рекуррентной сети с долгой краткосрочной памятью представлено на рисунках 20, 21.

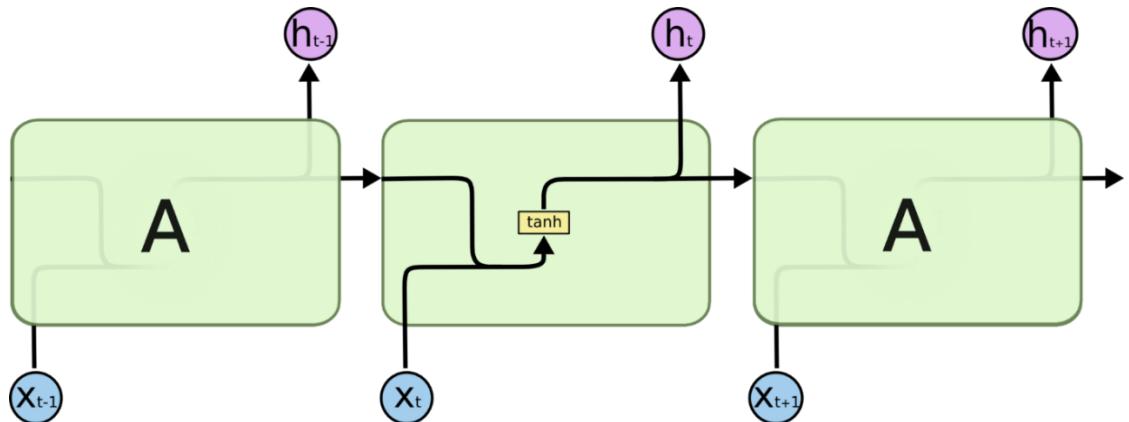


Рисунок 20 - Структура модуля рекуррентной нейронной сети

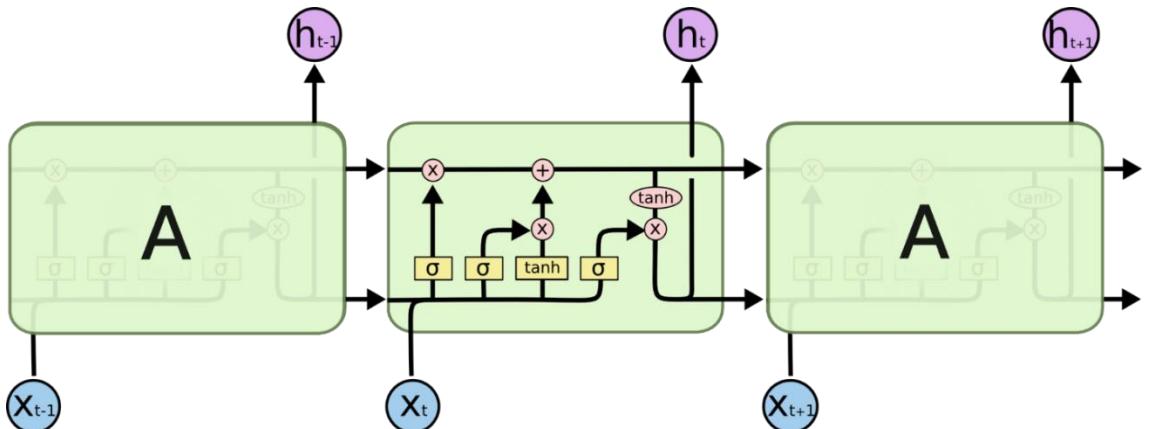


Рисунок 21 - Структура модуля рекуррентной нейронной сети с долгой краткосрочной памятью

Далее подробно рассматривается принцип работы ячейки памяти LSTM-сети.

Основной идеей сетей LSTM является состояние LSTM-ячейки. На рисунке 22 оно изображено с помощью горизонтальной линии в верхней части ячейки.

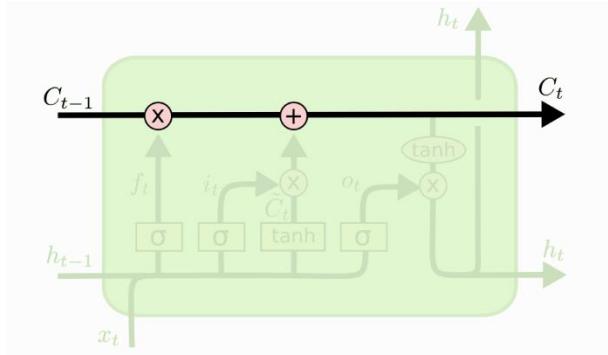


Рисунок 22 - Состояние LSTM-ячейки

Таким образом, каждая LSTM-ячейка имеет два выхода – выходной сигнал и сигнал состояния ячейки. Именно состояние ячейки позволяет хранить информацию в течение длительного промежутка времени. Оно передается последовательно по модулям сети. Процесс регулирования информации, которая поступает от одного этапа работы сети к другому, осуществляется с помощью фильтров (анг. gates). Фильтры позволяют пропускать информацию на основании некоторых условий.

Структура фильтра показана на рисунке 23. Каждый фильтр состоит из одного слоя нейронной сети с сигмоидальной функцией активации, а также операции побитового умножения. Сигмоидальный слой возвращает числа от нуля до единицы, которые обозначают, какую долю каждого блока информации следует пропустить дальше по сети.

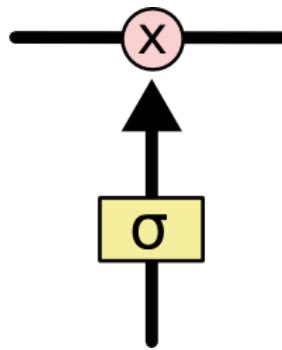


Рисунок 23 – Структура фильтра LSTM-ячейки

На первом шаге работы LSTM-модуля определяется, какую информацию можно удалить из сигнала состояния. Для этого существует сигмоидальный слой, или слой фильтра забывания (анг. forget gate layer), который показан на рисунке 24. Работа фильтра забывания описывается уравнением (30):

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f), \quad (30)$$

где h_{t-1} – выходной сигнал сети на предыдущем шаге,

x_t – сигнал, поступающий на вход сети,

W_f – матрица весов,

b_f – смещение,

f_t – выходной сигнал слоя фильтра забывания,

σ – сигмоидальная функция активации.

В дальнейших формулах используются аналогичные обозначения с измененными индексами.

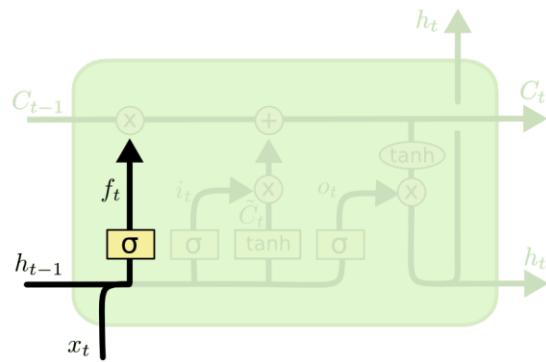


Рисунок 24 - Первый этап работы LSTM-ячейки

На следующем этапе определяется, какая информация будет занесена в состояние ячейки. Данный этап можно разбить на две части, его составляющие показаны на рисунке 25.

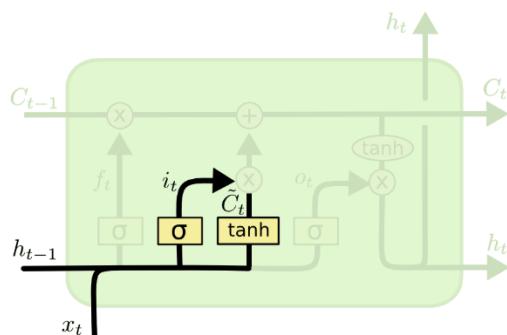


Рисунок 25 - Второй этап работы LSTM-ячейки

Сначала сигмоидальный слой, или слой входного фильтра (анг. input layer gate) определяет, какие значения следует обновить:

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i). \quad (31)$$

Затем слой, функцией активации которого является гиперболический тангенс, строит вектор новых значений \tilde{C}_t - кандидатов, которые можно добавить в состояние ячейки:

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C), \quad (32)$$

где \tanh – функция активации гиперболический тангенс.

Далее следует этап замены старого состояния LSTM-ячейки C_{t-1} на значение C_t , полученное на текущем шаге:

$$C_t = f_t \cdot C_{t-1} + i_t \cdot \tilde{C}_t \quad (33)$$

Схематически этап замены состояния LSTM-ячейки изображен на рисунке 26.

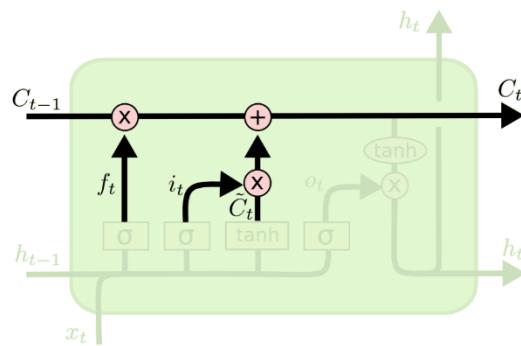


Рисунок 26 - Этап замены состояния LSTM-ячейки

На последнем этапе определяется выходной сигнал LSTM-ячейки. Выходной сигнал рассчитывается по входным данным, а также по текущему состоянию ячейки с применением некоторых фильтров:

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o), \quad (34)$$

$$h_t = o_t \cdot \tanh(C_t), \quad (35)$$

Выходной слой, а также функция гиперболического тангенса, работающие на данном этапе работы сети, выделены на рисунке 27.

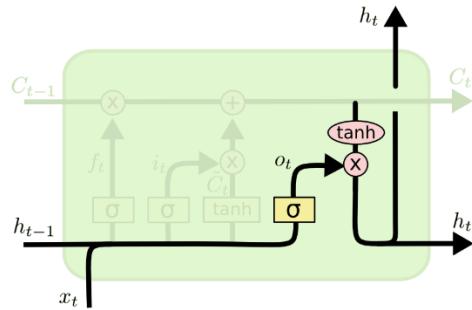


Рисунок 27 - Этап определения выходного сигнала LSTM-ячейки

4.3. Автокодировщик

В связи с нехваткой размеченных данных задачи обнаружения аномалий во временных рядах относятся к типу обучения без учителя. В задачах обучения без учителя востребовано применение такого распространенного типа нейронных сетей, как автокодировщик (анг. autoencoder).

Впервые модель автокодировщика была представлена еще в 1986 году в классической работе Дэвида Румельхарта, Джекфри Хинтона и Рональда Уильямса “Learning internal representations by error propagation”. С тех пор появилась масса различных вариантов автокодировщиков, но основная идея остается той же самой, и данный тип архитектуры нейронных сетей в целом только набирает популярность благодаря своей простоте и гибкости [20].

Основная идея автокодировщиков заключается в преобразовании задачи обучения без учителя в задачу обучения с учителем. Для этого модель сначала обучается выдавать на выходе ровно тот же пример, что подавался на вход. При этом на первом этапе модель обучается создавать некое внутреннее представление, кодировать вход какими-то признаками, а потом декодировать их обратно, чтобы восстановить исходный вектор входов. Иными словами, задачу автокодировщика можно выразить формулой (36):

$$f(X, \theta) \approx X, \quad (36)$$

где θ – параметры нейронной сети,

X – вектор входных значений.

Двумя основными компонентами автокодировщика являются две нейронные сети, одна из которых называется кодировщиком (анг. encoder), а другая – декодировщиком (анг. decoder).

Структуру автокодировщика хорошо отражает рисунок 28.

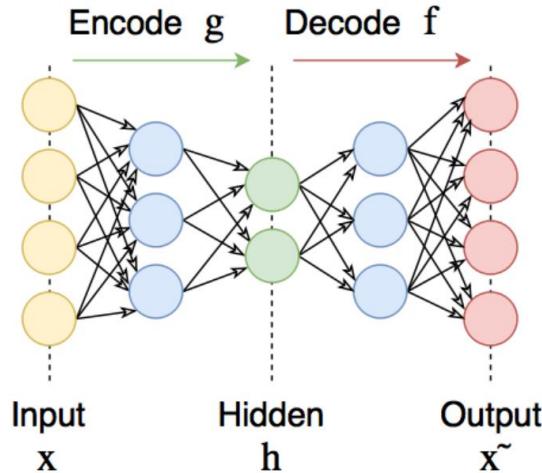


Рисунок 28 - Структура простого автокодировщика

Задачей кодировщика является формирование сжатого представления входных данных, то есть кодировщик переводит входной сигнал в его код (представление):

$$H = g(X). \quad (37)$$

Декодировщик представляет собой отражение кодировщика и предназначен для восстановления исходных данных по их коду с максимально возможной точностью:

$$\tilde{X} = f(H), \quad (38)$$

$$\tilde{X} \approx X. \quad (39)$$

В процессе обучения декодировщик стимулирует формирование наиболее информативного сжатого представления. Чем точнее восстановленный вход соответствует оригиналу, тем лучше сжатое представление.

В классическом автокодировщике, который и предлагался в начальных работах, чтобы на скрытом слое нельзя было просто скопировать вход, было предложено простое ограничение - уменьшение размерности скрытого слоя по

сравнению с размерностью входа. Сейчас существует множество типов автокодировщиков – шумоподавляющие, разреженные, вариационные и другие.

Таким образом, задачей автокодировщика является получение на выходе значений, максимально близких ко входным данным. При этом модель обучается выбирать наиболее значимые признаки входных данных, используя для этого наименьшее возможное количество параметров [21].

4.4. LSTM-автокодировщик

Задача LSTM-автокодировщика остается такой же, как и у обычновенного последовательного автокодировщика. При этом вместо обычных слоев в частях кодировщика и декодировщика используются LSTM-слои, где вместо отдельно взятых нейронов находятся LSTM-модули. Данная модификация позволяет учитывать временные тренды в исходных данных [22]. Структура LSTM-автокодировщика и ее представление в развернутом виде показаны на рисунках 29, 30.

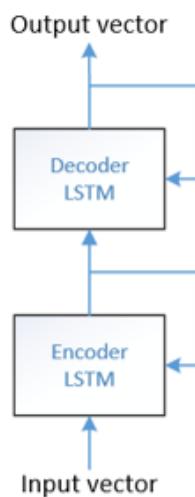


Рисунок 29 - Структура LSTM-автокодировщика

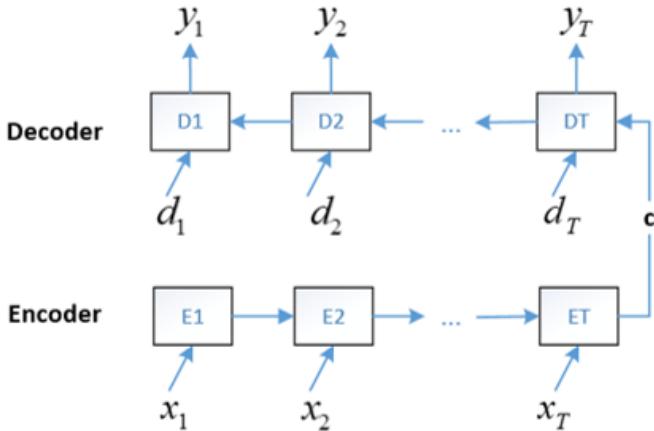


Рисунок 30 - Структура LSTM-автокодировщика в развернутом виде

4.5. Аугментация данных

Для обеспечения корректности работы алгоритма требуется прогонять его в тестовом режиме на большом количестве различных наборов данных. Получение необходимого числа тестовых данных, удовлетворяющих заявленным условиям, является весьма нетривиальной задачей. В связи с этим в машинном обучении существует специальная методика, позволяющая создавать дополнительные обучающие данные из уже имеющихся – аугментация данных.

Аугментация данных – процесс генерации новых данных с помощью трансформации исходного тренировочного набора [23].

Различные подходы по аугментации данных рассмотрены в работах [24], [25], [26]. В статье [26] предложено деление существующих подходов к аугментации данных временных рядов на базовые и прогрессивные. К базовым методам относятся вращение, зеркальное отражение, сжатие и растяжение вдоль оси, временные сдвиги, добавление шума, скачков и др. При этом большинство базовых методов применяются во временном представлении данных, однако существуют способы, работающие с частотно-временным и частотным представлениями.

К прогрессивным методам относят декомпозицию, модельные методы и глубокое обучение. Декомпозиция заключается в разложении сигнала на тренд, сезонность и оставшуюся часть. Затем для создания новых временных рядов используется рекомбинация детерминированных и стохастических компонент.

Суть методов аугментации с помощью глубокого обучения состоит в том, чтобы трансформировать сигнал посредством модификации его сжатого признакового пространства. Такой подход имеет лучшую результативность, нежели модификация необработанных «сырых» данных. Сжатое признаковое пространство может быть получено с помощью последовательного автокодировщика. Затем для генерации новых последовательностей используется интерполяция и экстраполяция.

Популярным методом глубокого обучения для создания новых данных является использование генеративно-состязательных нейронных сетей (анг. Generative Adversarial Network, GAN). Такие сети генерируют синтетические данные и эффективно расширяют тестовый набор данных.

В рамках данной работы рассмотрены базовые методы аугментации данных, применяемые ко временному представлению данных, а также метод декомпозиции.

Из базовых методов к исходному дискретному электрокардиографическому сигналу $X(n)$, где n – номер отсчета, могут быть применены следующие:

- a) Зашумление сигнала

При этом виде аномалии происходит наложение гауссовского шума, то есть шума, плотность вероятности которого равна плотности вероятности нормального распределения. Накладываемый шум имеет фиксированные параметры, соответствующие параметрам стандартного нормального распределения: математическое ожидание $\mu = 0$ и среднеквадратическое отклонение $\sigma = 1$. Зашумление сигнала для i -го отсчета времени:

$$X[i] = X[i] + noise(\mu, \sigma). \quad (40)$$

- б) Добавление скачков

В данном случае значение сигнала в i -ый момент времени изменяется на случайное число из выбранного диапазона значений сигнала, умноженное на коэффициент. Диапазон значений выбирается случайно: либо от среднего значения амплитуды сигнала до максимального значения, либо от минимального значения амплитуды до среднего:

$$X[i] = \alpha * \text{random}(\text{mean}(X), \text{max}(X)), \quad (41)$$

$$X[i] = \alpha * \text{random}(\text{min}(X), \text{mean}(X)). \quad (42)$$

При этом значения сигнала в окрестности i -ого отсчета времени изменяются по линейному закону, чтобы аномалия была выражена не единичной точкой.

Метод декомпозиции в данной работе осуществляется следующим образом: сигнал раскладывается на аддитивные компоненты (грубую копию сигнала и детализирующую составляющую), затем компонента шума умножается на положительную константу $\alpha > 1$ и прибавляется к тренду:

$$X[i] = \text{trend}[i] + \alpha * \text{noise}[i]. \quad (43)$$

5. Описание разработанного алгоритма

5.1. Используемые программные средства

Для программной реализации был выбран язык программирования Python. Его выбор был обусловлен наличием большого количества программных средств, предназначенных для работы с нейронными сетями. В данной работе в качестве среды глубокого обучения была выбрана библиотека Keras. Keras является открытой нейросетевой библиотекой, написанной на языке Python. Она представляет собой надстройку над фреймворком TensorFlow и нацелена на оперативную работу с сетями глубинного обучения, при этом спроектирована так, чтобы быть компактной, модульной и расширяемой.

Ключевыми структурами данных для построения нейронных сетей в Keras являются слои (анг. layers) и модели (анг. models). При этом модель представляет собой граф слоёв [27]. Keras позволяет конструировать модели различных уровней сложности – от простого стека слоёв до моделей с несколькими входами и выходами, моделей с общими слоями и моделей с непоследовательными потоками данных.

Одним из достоинств Keras является поддержка графического (анг. Graphics Processing Unit, GPU) и тензорного (анг. Tensor Processing Unit, TPU) процессоров Google. Тензорный процессор Google - это нейронный процессор, являющийся специализированной интегральной схемой, разработанной корпорацией Google и предназначенный для использования с фреймворком машинного обучения TensorFlow. Доступ GPU и TPU Google осуществляется посредством Google Colab - облачного сервиса на основе Jupyter Notebook.

Для обучения нейронных сетей требуются большие вычислительные мощности. Так как Google Colab предоставляет всё необходимое для машинного обучения прямо в браузере и даёт бесплатный доступ к невероятно быстрым GPU и TPU, он был выбран в качестве среды разработки.

5.2. Программная реализация

Структуру разработанного алгоритма можно представить в виде блок-схемы, изображенной на рисунке 31.



Рисунок 31 - Структура разработанного алгоритма

В качестве исходных сигналов на вход программы поступают записи ЭКГ, взятые с интернет-портала PhysioNet.

Так как данные содержат различного рода помехи, в алгоритме присутствует этап помехоподавления. Данный этап включает в себя последовательное применение низкочастотного фильтра Баттервортса и фильтра на основе быстрого вейвлет-преобразования. Низкочастотный фильтр Баттервортса пропускает частоты ниже частоты среза и подавляет высокочастотные шумы (листинг 1).

```
def butter_lowpass(y, cutoff, sample_rate, order):  
    nyq_freq = 0.5 * sample_rate  
    normal_cutoff = cutoff / nyq_freq  
    b, a = signal.butter(order, normal_cutoff, btype='low', analog=False)  
    rec=signal.lfilter(b,a,y)  
    return rec
```

Листинг 1 - Низкочастотный фильтр Баттервортса на языке Python

Задачей фильтра на основе быстрого вейвлет-преобразования является удаление из сигнала низкочастотных помех, таких как дрейф изолинии. БВП раскладывает сигнал на аппроксимирующие и детализирующие вейвлет-коэффициенты. После восстановления сигнала только по его аппроксимирующему коэффициентам получается его грубая копия. Затем грубая копия сигнала вычитается из самого сигнала, уже очищенного от высокочастотных шумов. Функция, реализующая фильтр на основе БВП, показана в листинге 2.

```

def highpassfilter(signal, mother_wavelet):
    coeffs = pywt.wavedec(signal, mother_wavelet,
mode="per")
    coeffs[1:]=(np.array([0.0 for j in range(len(i))])
]) for i in coeffs[1:])
    reconstructed_signal = pywt.waverec(coeffs,
mother_wavelet, mode="per")
    rec=signal-reconstructed_signal
    return rec

```

Листинг 2 – Фильтр на основе БВП на языке Python

Таким образом, после этапа предобработки из сигнала удаляются как низкочастотные, так и высокочастотные шумы, препятствующие эффективности работы алгоритма.

Этап обнаружения аномалий состоит из проектирования нейронной сети, ее обучения и тестирования. В ходе проведенного исследования было выяснено, что с задачей обнаружения временных зависимостей в данных лучше всего справляются рекуррентные нейронные сети. При этом наилучшей конфигурацией нейронных сетей для решения поставленной задачи являются LSTM-сети, это обусловлено их способностью хранить нужную информацию с предыдущих этапов работы сети на протяжении длительного времени.

Так как проблемой задач обнаружения аномалий в данных является нехватка размеченных данных, то такие задачи относятся к типу обучения без учителя. В связи с этим популярной архитектурой нейронных сетей, используемой в данном случае, является автокодировщик.

Приняв во внимание перечисленные выше особенности задачи, было решено использовать для ее решения такую архитектуру нейронных сетей, как LSTM-автокодировщик.

Сигнал, поступающий на вход нейронной сети, разделен на части с помощью алгоритма скользящего окна. Экспериментальным путем был

подобран наилучший размер окна, равный 50 временным отсчетам, шаг скольжения при этом составляет 1.

Реализованная модель LSTM-автокодировщика представлена в листинге 3. Видно, что кодировщик и декодировщик содержат по два LSTM-слоя. Каждый из LSTM-слоев содержит по одному повторяющемуся LSTM-модулю, который принимает на вход трехмерный тензор, имеющий следующую форму: [количество экземпляров данных; размер скользящего окна; количество признаков]. Данные поступают на вход сети в нормализованном виде. Каждый модуль переводит данные в новое признаковое пространство с размерностью 64. Функцией активации каждого модуля является гиперболический тангенс. В качестве функции потерь модели была использована среднеквадратическая ошибка (анг. Mean Squared Error, MSE), вычисляемая по формуле (44):

$$MSE = \frac{1}{N} \sum_{i=0}^{N-1} (Y_i - \tilde{Y}_i)^2, \quad (44)$$

где Y_i – истинное значение сигнала в i -ый момент времени,

\tilde{Y}_i – значение сигнала в i -ый момент времени, полученное в результате работы нейронной сети,

N – количество отсчетов.

Кодировщик создает сжатое представление входных данных, декодировщик учится восстанавливать данные по их сжатому представлению. Между кодировщиком и декодировщиком находится слой, называемый RepeatVector. Он предназначен для модификации двумерного тензора, полученного на выходе кодировщика, в трехмерный – требуемый на входе декодировщика. Последним слоем модели является слой TimeDistributed. Он используется для обработки вывода из предыдущего слоя LSTM.

```

lstm_autoencoder = Sequential()
lstm_autoencoder.add(LSTM(64, activation='tanh',
input_shape=(x_train.shape[1],x_train.shape[2]),
return_sequences=True))
lstm_autoencoder.add(LSTM(64, activation='tanh',
return_sequences=False))
lstm_autoencoder.add(RepeatVector(x_train.shape[1]))
lstm_autoencoder.add(LSTM(64, activation='tanh',
return_sequences=True))
lstm_autoencoder.add(LSTM(64, activation='tanh',
return_sequences=True))
lstm_autoencoder.add(TimeDistributed(Dense
(x_train.shape[2])))
lstm_autoencoder.compile(optimizer='adam',
loss='mean_squared_error')

```

Листинг 3 – LSTM-автокодировщик на языке Python

LSTM-автокодировщик обучается исключительно на данных, принадлежащих нормальному классу. Процесс обучения длится в течение 150 эпох. Затем для обучающей выборки и значений, восстановленных в процессе обучения, находится скользящее среднее значение с применением скользящего окна, размером 30 временных отсчетов. Данная процедура выполняется для сглаживания краткосрочных колебаний. По полученным массивам скользящих средних значений находится их разница и строится её распределение, на основании которого выбирается пороговое значение, являющееся критерием по определению аномальных участков данных.

Обученная модель применяется для восстановления тестовых данных. К исходному и восстановленному сигналу также применяется функция нахождения скользящего среднего значения. Разность сглаженных значений исходного и восстановленного сигнала называется ошибкой восстановления.

Участки, на которых, ошибка восстановления превышает определенный ранее порог, идентифицируются как аномальные.

5.3. Визуализация результатов работы алгоритма

Так как особенностью задач обнаружения аномалий является нехватка данных аномального класса, то для тестирования реализованной модели LSTM-автокодировщика были созданы синтетические данные. Они создавались на основе реальных записей сигналов, в которых отсутствовали экземпляры аномального класса, с помощью методов аугментации, описанных в разделе 4.5.

Записи ЭКГ были взяты из базы данных Challenge 2018 Test Set, находящейся в открытом доступе на интернет-портале PhysioNet. Необходимо отметить, что все используемые для обучения и тестирования записи сигналов принадлежат одному набору данных. Данное ограничение обусловлено существенными различиями записей, принадлежащих разным наборам. К таким различиям относятся частота дискретизации, снятие ЭКГ с различных отведений и др. Этот набор данных был выбран по причине наличия в нем зашумленных неотфильтрованных сигналов, что позволяет протестировать полный алгоритм на одних данных.

Необходимо также учитывать, что данная работа не претендует на классификацию обнаруженных аномалий или постановку диагноза. Задачей является обнаружение последовательности, не соответствующей общей закономерности.

На рисунке 32 показан исходный сигнал с искусственно синтезированными аномалиями.

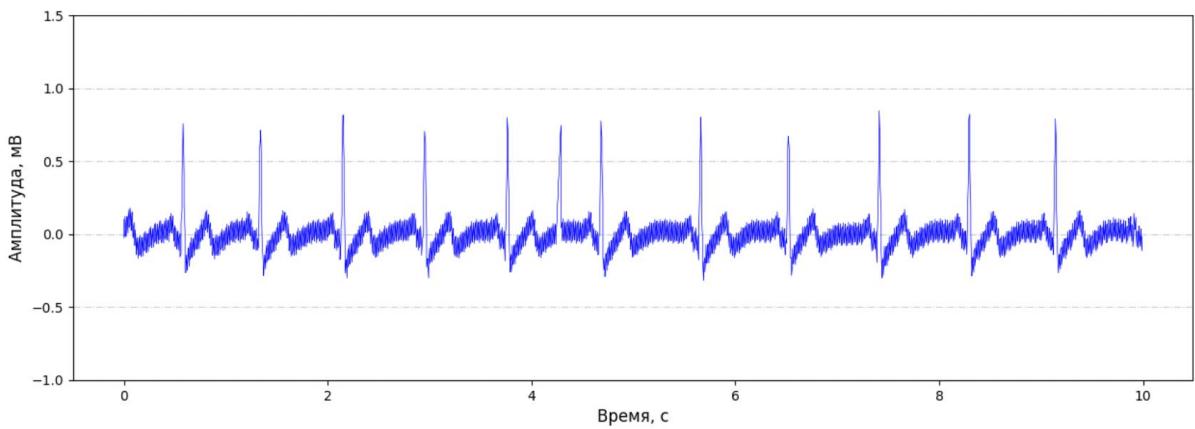


Рисунок 32 - Исходный сигнал из набора данных Challenge 2018 Test Set с искусственно синтезированными аномалиями

Видно, что данные сильно зашумлены – в них присутствуют шумы от линий питания аппаратуры. Это подтверждает спектр частот сигнала, изображенный на рисунке 33. По рисунку видно, что основная амплитуда находится на частоте 60 Гц, которая является сетевой частотой.

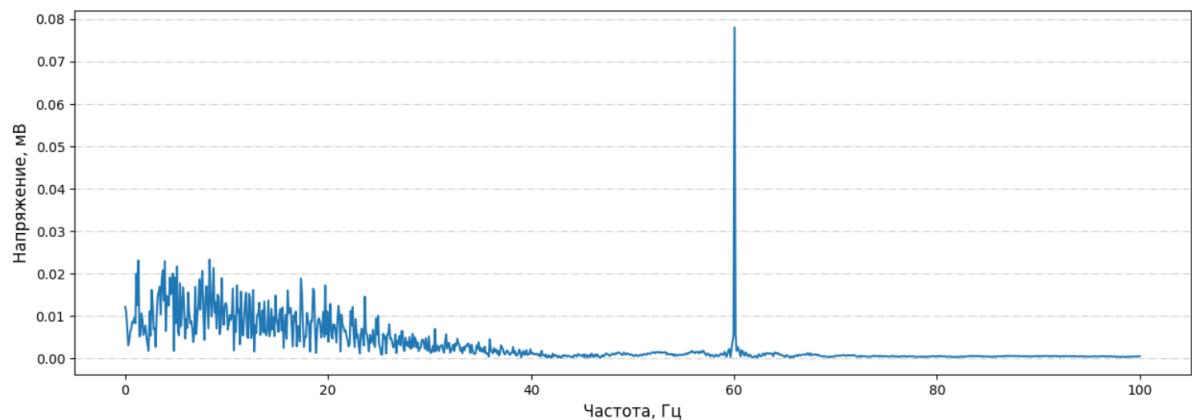


Рисунок 33 - Спектр Фурье исходного сигнала с искусственно синтезированными аномалиями

В результате работы этапа помехоподавления исходный сигнал приобретает вид, как на рисунке 34 (в).

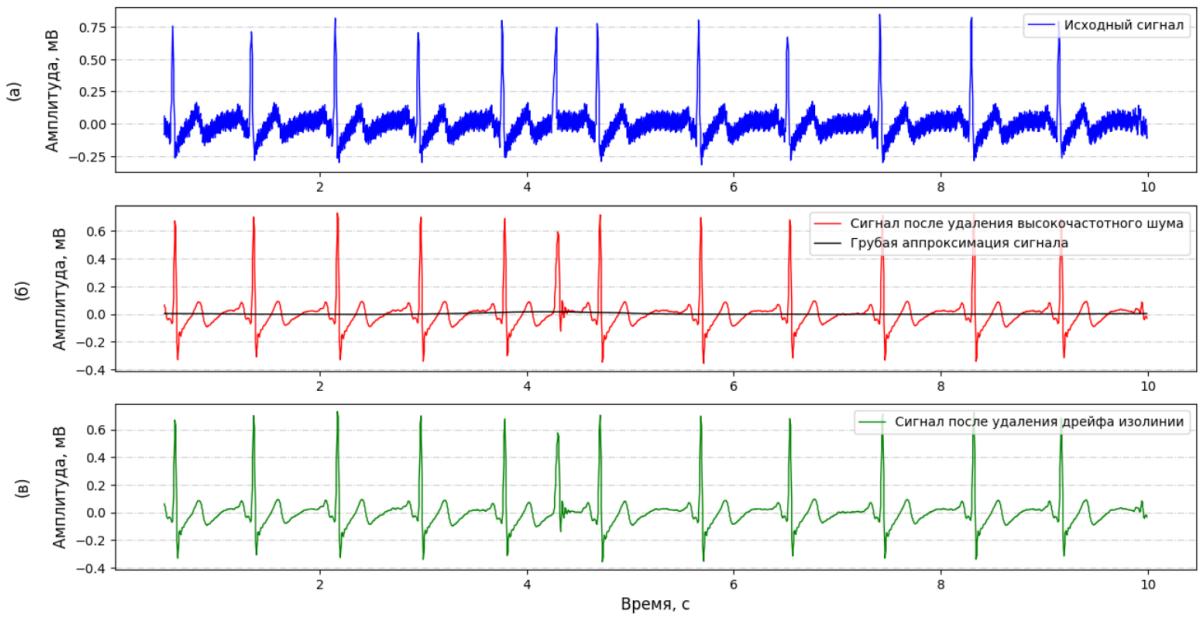


Рисунок 34 – Результат работы этапа помехоподавления на примере исходного сигнала с искусственно синтезированными аномалиями: (а) исходный сигнал; (б) сигнал после удаления высокочастотных шумов; (в) сигнал после удаления высокочастотного шума и дрейфа изолинии

Отфильтрованный сигнал разделяется на обучающую и тестовую выборки, как показано на рисунке 35. Обучающая выборка обозначена зеленым цветом, а тестовая – синим.

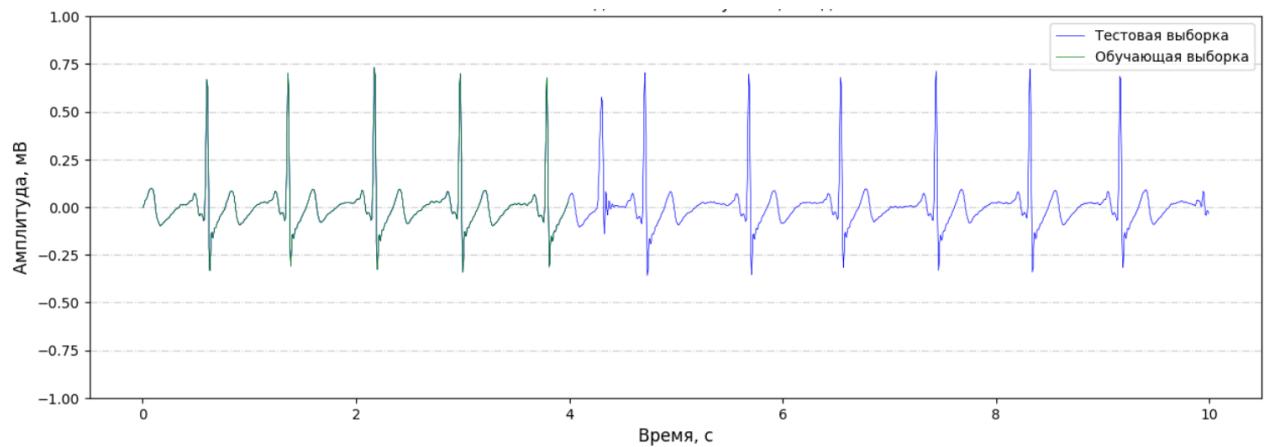


Рисунок 35 – Разделение отфильтрованного сигнала с синтезированными аномалиями на обучающую и тестовую выборки

После обучения построенной модели нейронной сети вычисляется пороговое значение, которое в дальнейшем используется в качестве индикатора аномальных областей. В разделе 5.2 было сказано, что пороговое значение

определяется по распределению разности скользящих средних значений, полученных в результате применения соответствующего фильтра к обучающей выборке и восстановленных на ее основе значений. Распределение, по которому определяется пороговое значение, показано на рисунке 36.



Рисунок 36 – Определение порогового значения

Далее на вход сети подается весь исходный сигнал. На рисунке 37 (а) синим цветом показан исходный сигнал и сигнал, полученный в результате работы нейронной сети. К этим двум сигналам также применяется фильтр скользящего среднего. По полученным усредненным сигналам вычисляется ошибка восстановления, показанная на рисунке 37 (б) зеленым цветом. Те области, где ошибка восстановления превышает заданное пороговое значение, выделяются как аномальные. На этом работа алгоритма завершается.

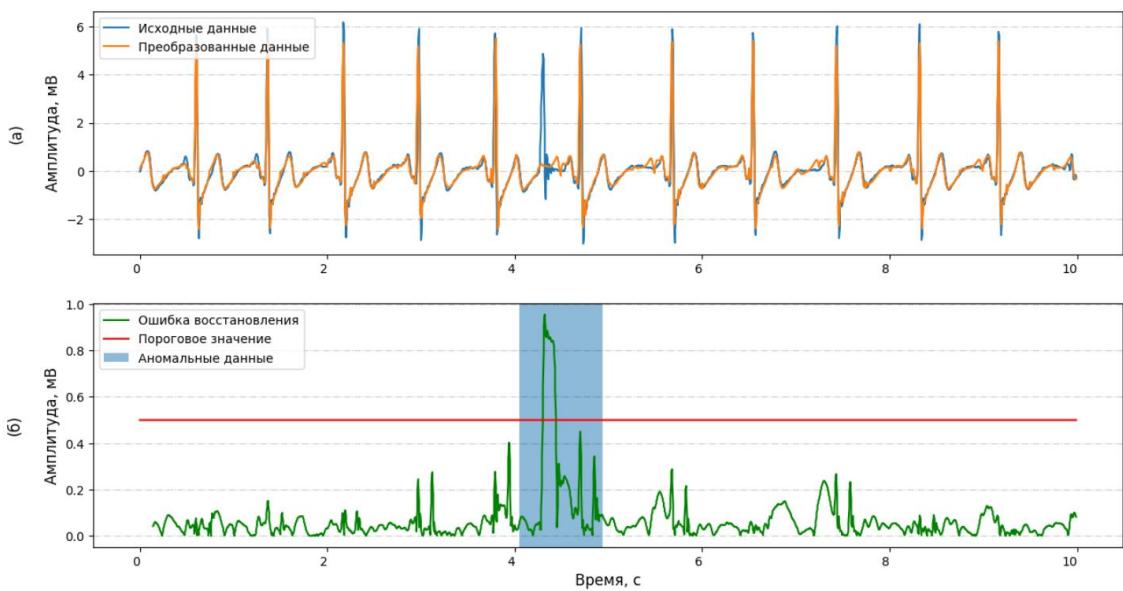


Рисунок 37 – Результат работы алгоритма на примере сигнала с искусственной аномалией: (а) сравнение исходных и полученных данных; (б) выделение аномальных областей

По рисунку 37 видно, что выделенная аномальная область соответствует области появления синтезированной аномалии в исходных данных.

Разработанный алгоритм был также протестирован на реальных данных. В качестве исходного сигнала с реальной аномалией послужила запись ЭКГ, изображенная на рисунке 38. На рисунке 39 изображен результат работы алгоритма на данном сигнале.

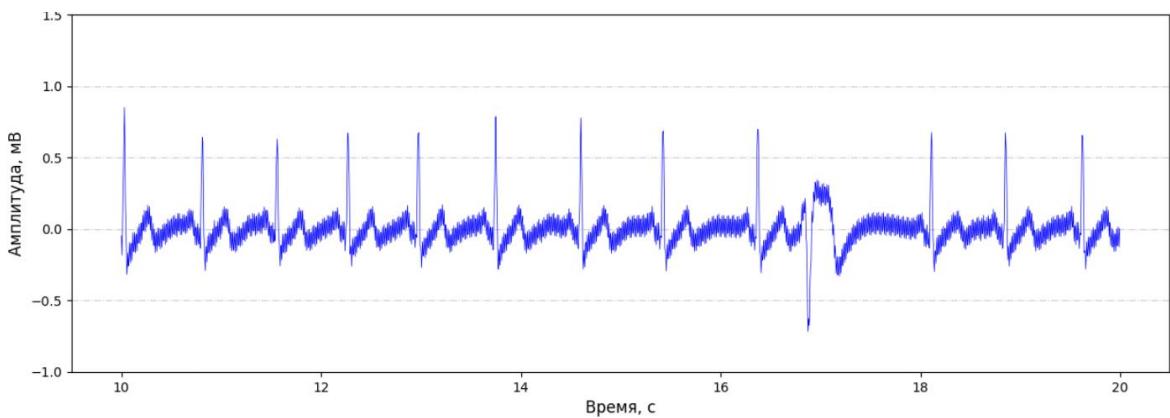


Рисунок 38 - Исходный сигнал с реальной аномалией

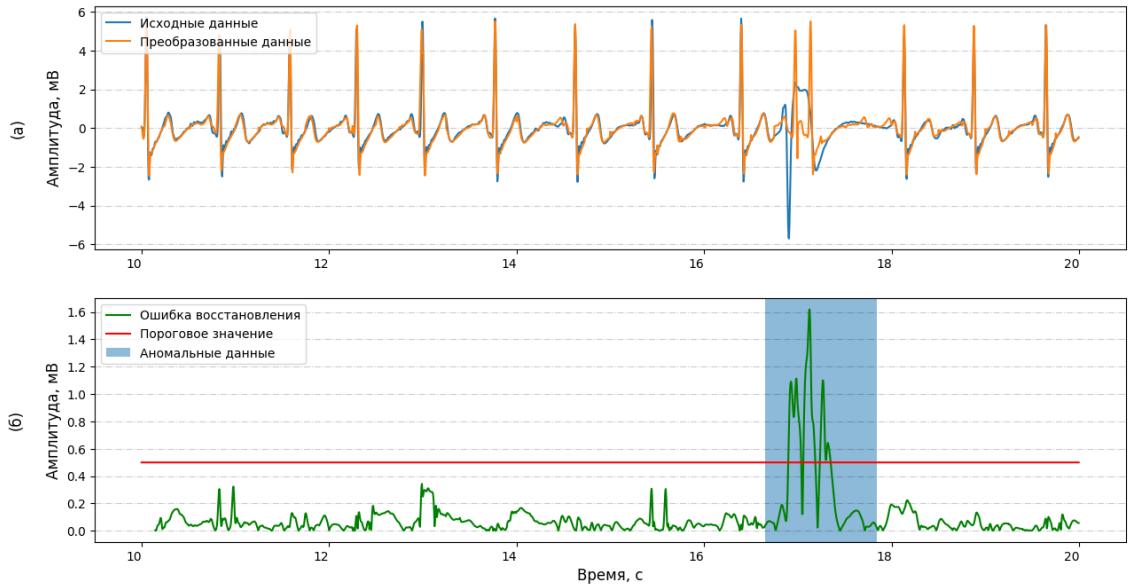


Рисунок 39 - Результат работы алгоритма на примере сигнала с реальной аномалией: (а) сравнение исходных и полученных данных; (б) выделение аномальных областей

Рисунки 37 и 39 доказывают работоспособность реализованного алгоритма.

ЗАКЛЮЧЕНИЕ

В рамках выпускной квалификационной бакалаврской работы был разработан алгоритм обнаружения аномалий в биомедицинских сигналах на примере электрокардиограмм.

Проведено исследование различных видов помех в электрокардиограммах, а также методов их устранения. Выполнена программная реализация таких методов фильтрации сигналов, как полосовой фильтр Баттервортса, низкочастотный фильтр Баттервортса, фильтрация с помощью скользящего среднего значения и фильтрация на основе БВП. После проведения сравнительного анализа перечисленных методов выбран оптимальный алгоритм помехоподавления в электрокардиографических сигналах.

Доказано преимущество использования рекуррентных нейронных сетей для решения поставленной задачи. Проведен обзор существующих архитектур нейронных сетей, применяемых в данной предметной области, и спроектирована модель, способная детектировать аномалии в данных, обладающих временными зависимостями.

Разработанная модель была проверена как на синтетических, так и на реальных данных. Полученные графики в обоих случаях демонстрируют хорошую работоспособность разработанного алгоритма.

Своевременное диагностирование аномалий играет важную роль во многих отраслях, однако иногда требуется не только их своевременное обнаружение, но и последующая классификация. По этой причине дальнейшая деятельность может быть направлена на расширение выполненного алгоритма, а именно добавление этапа классификации аномалий.

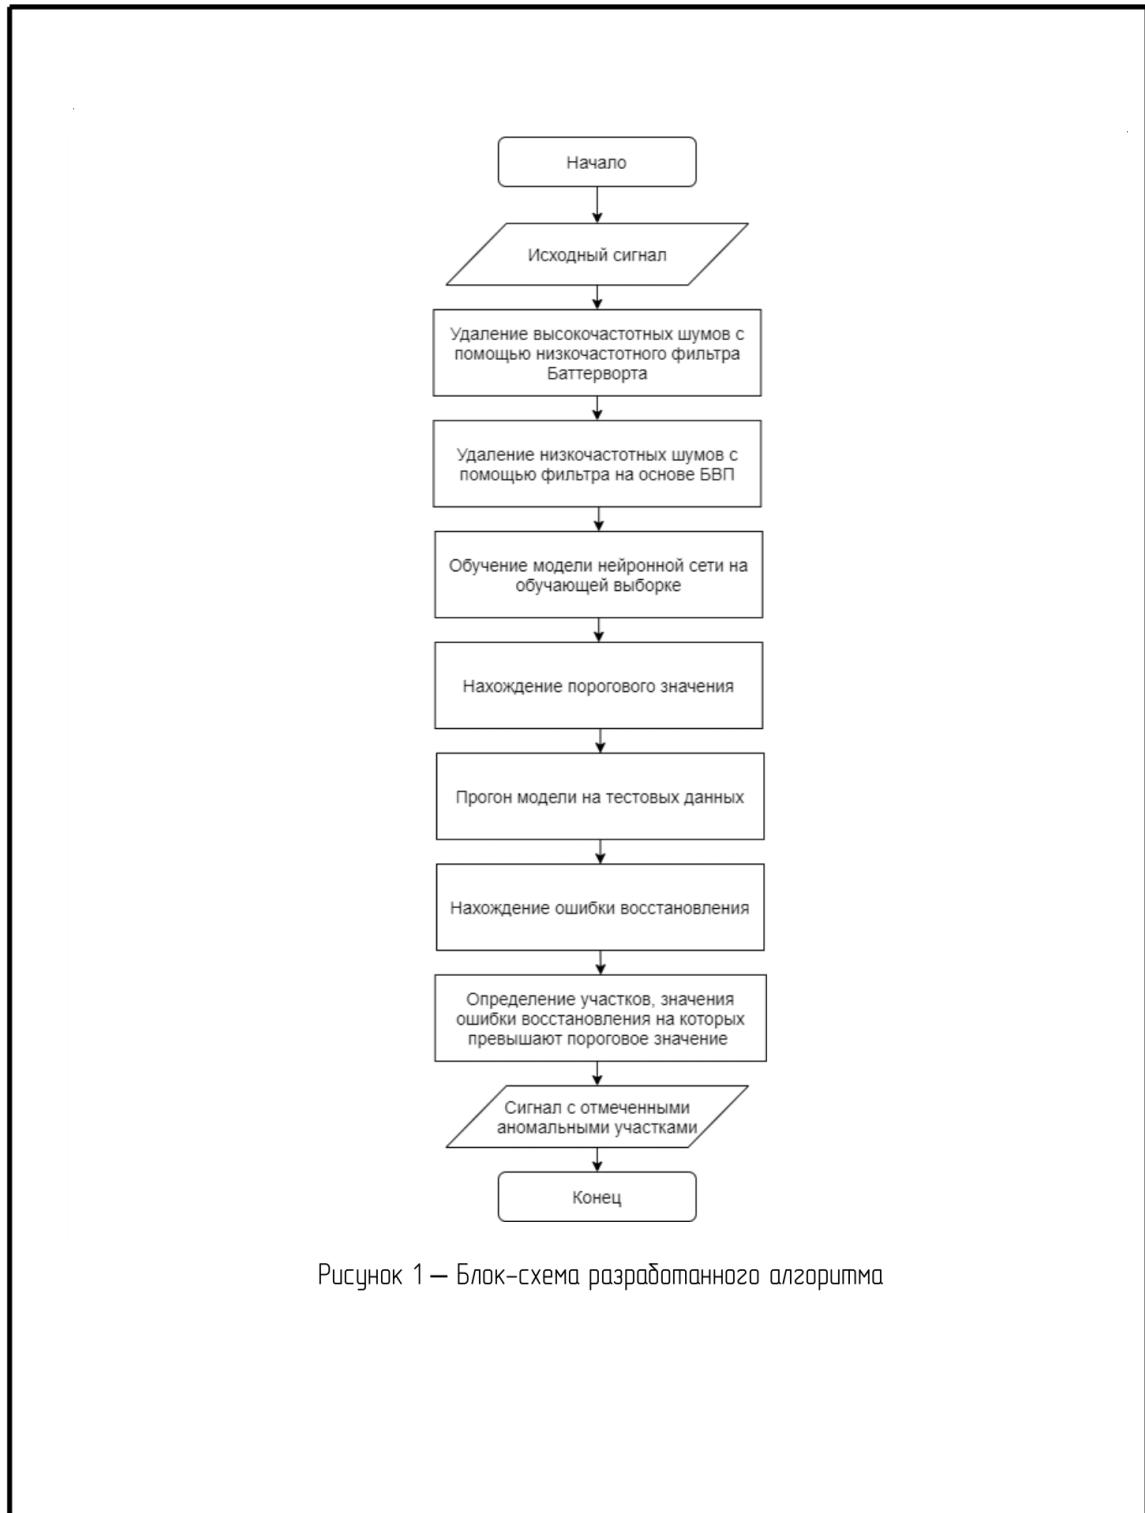
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Chandola, V. Anomaly detection: A survey / V. Chandola, A. Banerjee, V. Kumar // ACM Computing Surveys. – 2009. - Vol. 41. - №3.
2. Федотов, А. А. Прикладной анализ биомедицинских сигналов: Комплекс методических указаний к лабораторным и практическим работам. – Самара: Самар. нац. исследов. ун-т., 2018. – 132 с.
3. Карпенко, А. П. Модифицированный метод классификации многомерных временных рядов с использованием шейплетов / А. П. Карпенко, П. И. Сотников // Вестник МГТУ им. Н. Э. Баумана. Сер. Приборостроение. - 2017. – №2. – С. 46-65.
DOI: 10.18698/0236-3933-2017-2-46-65
4. Kher, R. Signal Processing Techniques for Removing Noise from ECG Signals / R. Kher // Journal of Biomedical Engineering and Research. — 2019. – Vol. 3. — P. 1-9.
5. Электрокардиография. — Текст : электронный // Grandars : [сайт]. — URL: <http://www.grandars.ru/college/medicina/elektrokardiografiya.html> (дата обращения: 20.03.2020).
6. Comparison of Baseline Wander Removal Techniques considering the Preservation of ST Changes in the Ischemic ECG: A Simulation Study / G. Lenis, N. Pilia, A. Loewe [and other] // Computational and Mathematical Methods in Medicine. — 2017.
7. Maggio, A. Quantification of Ventricular Repolarization Dispersion Using Digital Processing of the Surface ECG / A. Maggio, M. Bonomini, E. Laciari, P. Arini // Advances in Electrocardiograms - Methods and Analysis. — 2012.
8. Медицинская электронная аппаратура для здравоохранения / Л. Кромвелл [и др.]; пер. с анг. М.К. Размахнина, ред. Р.И. Утямышева. — Москва: Издательство «Радио и связь», 1981. — с. 344.

9. Титце, У. Полупроводниковая схемотехника / У. Титце, К. Шенк; пер. с нем. под ред. док-ра техн. наук А. Г. Алексеенко. — Москва: Издательство «Мир», 1982. — с. 512.
10. Кирьянов, Д. В. Вычислительная физика / Д. В. Кирьянов, Е. Н. Кирьянова. — М: Полибук Мультимедиа, 2006. - 352.с.
11. Микушин А. В. Лекции по курсу «Цифровая обработка сигналов»: сайт. — Текст: электронный. — URL: <http://digteh.ru/dsp/> (дата обращения 01.04.20).
12. Ульянова, Ю. Е. Частотно-временные преобразования, используемые в цифровой обработке сигналов / Ю. Е. Ульянова, Р. Г. Бабенко, А. В. Чернов // Глобальная ядерная безопасность. – 2015. - №3. – С. 36-42.
13. Максименко, Г. А. Метод обнаружения аномалий потоков данных в сетях // Системы обработки информации. – 2009. - №7 (81). – С. 33 – 37.
14. Астафьева, Н. М. Вейвлет-анализ: основы теории и примеры применения // Успехи физических наук. - 1996. - Том 166, №11. – С. 1145 – 1170.
15. Яковлев, А. Н. Введение в вейвлет-преобразования. – Новосибирск, 2003. – 104 с.
16. Nagendra, H. Application of Wavelet Techniques in ECG Signal Processing: An Overview / H. Nagendra, S. Mukherjee, V. Kumar // International Journal of Engineering, Science and Technology. — 2011. — № 10. — С. 7436-7443.
17. Rai, H. M. ECG signal processing for abnormalities detection using multi-resolution wavelet transform and Artificial Neural Network classifier / H. M. Rai, A. Trivedi, S. Shukla // Measurement. — 2013. — № 46. — С. 3238-3246.
18. Николенко, С. И. Глубокое обучение / С. И. Николенко, А. А. Кадурин, Е. О. Архангельская. – С.-Петербург: Питер, 2018. - 480 с.
19. Deep Learning Tutorial. - LISA lab, University of Montreal, 2015. URL: <http://deeplearning.net/tutorial/deeplearning.pdf>

20. Olah, C. Understanding LSTM Networks / C. Olah. — Текст: электронный // GitHub: [сайт]. — URL: <http://colah.github.io/posts/2015-08-Understanding-LSTMs/> (дата обращения: 18.05.2020).
21. Valkov, V. Time Series Anomaly Detection with LSTM Autoencoders using Keras in Python / V. Valkov. — Текст: электронный // Curiously: [сайт]. — URL: <https://www.curiously.com/posts/anomaly-detection-in-time-series-with-lstms-using-keras-in-python/> (дата обращения: 18.05.2020).
22. LSTM-based Encoder-Decoder for Multi-sensor Anomaly Detection / P. Malhotra, A. Ramakrishnan, G. Anand and others. — Текст: электронный // arxiv.org: [сайт]. — URL: <https://arxiv.org/pdf/1607.00148.pdf> (дата обращения: 14.05.20).
23. Fawzi, A. Adaptive data augmentation for image classification / A. Fawzi, H. Samulowitz, D. S. Turaga, P. Frossard // IEEE International Conference on Image Processing. — 2016. — P. 3688-3692.
24. Gavrin S., Murzagulov D., Zamyatin A. Anomaly Detection in Process Signals within Machine Learning and Data Augmentation Approach // 15th International Conference on Machine Learning and Data Mining. – 2019. – P. 585-598.
25. Pandey S. K. Automatic detection of arrhythmia from imbalanced ECG database using CNN model with SMOTE / S. K. Pandey, R. R. Janghel // Australasian Physical & Engineering Sciences in Medicine . — 2019.
26. Time Series Data Augmentation for Deep Learning: A Survey / Q. Wen, L. Sun, X. Song and others. — Текст: электронный // arXiv preprint arXiv: [сайт]. — URL: <https://arxiv.org/pdf/2002.12478.pdf> (дата обращения: 20.04.2020).
27. Обзор Keras. — Текст : электронный // tensorflow.org : [сайт]. — URL: <https://www.tensorflow.org/guide/keras/overview?hl=ru> (дата обращения: 11.05.2020).

**ПРИЛОЖЕНИЕ А Графическая часть выпускной квалификационной
работы**



Выпускная квалификационная работа				
Изм.	Лист	№ докум.	Подпись	Дата
Разработала	Арбузова А. В.			
Проверила	Волосатова Т. М.			
Н. Контр.				
Утв.				

Обнаружение аномалий в биомедицинских
сигналах с использованием рекуррентных
нейронных сетей

Литера	Лист	Листов
	1	5

МГТУ им. Н.Э. Баумана

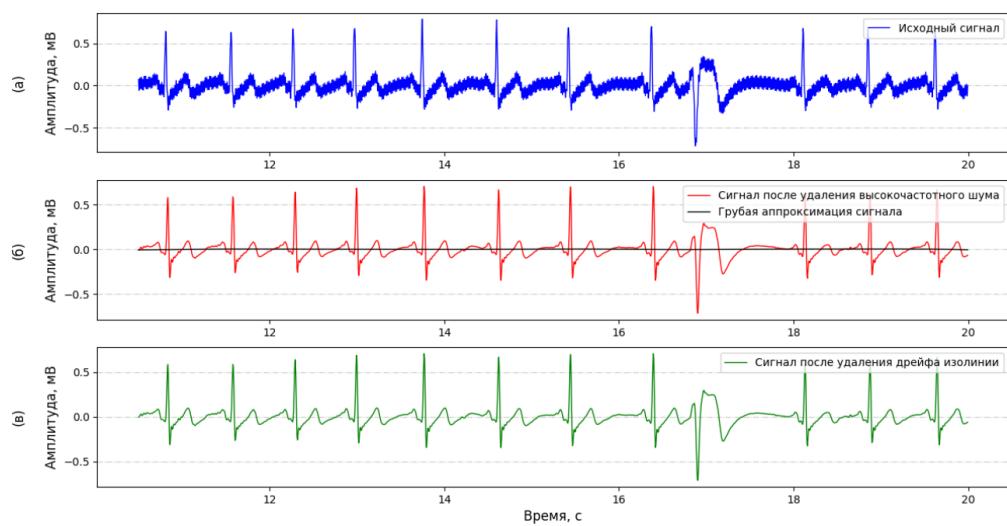


Рисунок 2 – Результат последовательного применения ФНЧ и ФВЧ

Изм.	Лист	№ ДОКУМ	Подпись	Дата	Лист
					2

Выпускная квалификационная работа



Рисунок 3 – Структура LSTM-автомодифицирущика

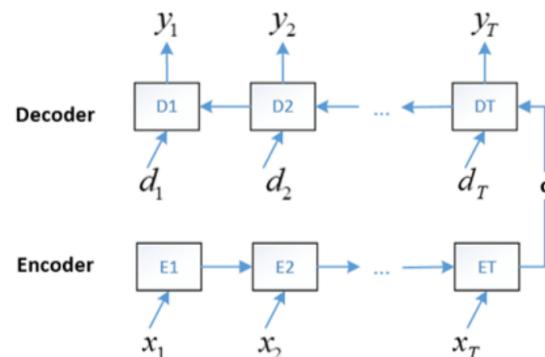


Рисунок 4 – Структура LSTM-автомодифицирущика в развернутом виде

Изм	Лист	№ докум	Подпись	Дата	Лист
					3

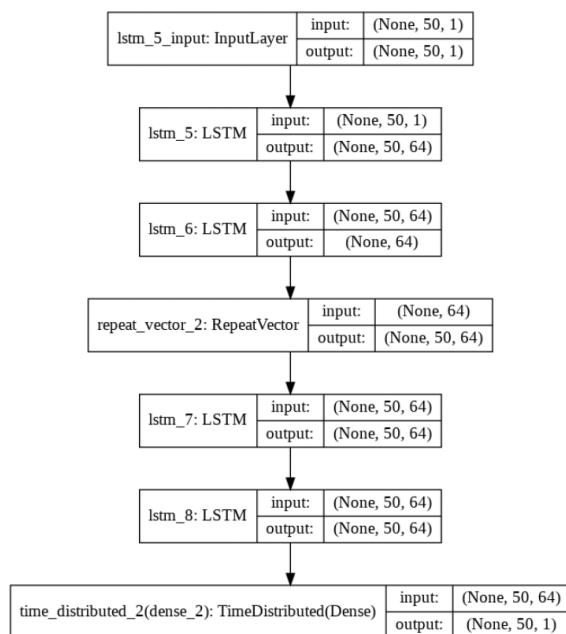


Рисунок 6 – Структура разработанной нейронной сети

Изм	Лист	№ докум	Подпись	Дата	Выпускная квалификационная работа	Лист
						4

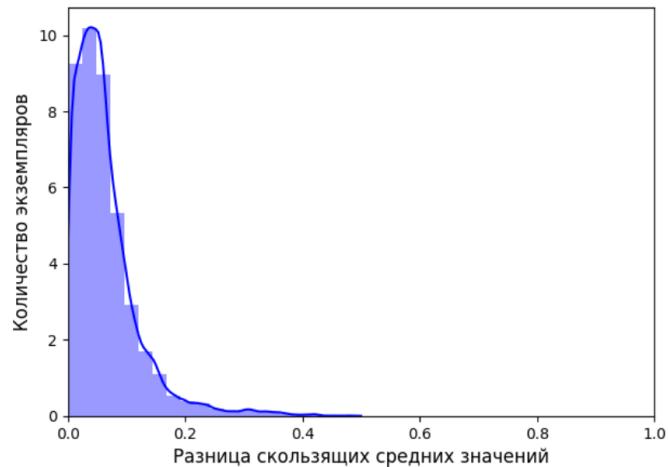


Рисунок 7 – Определение порогового значения

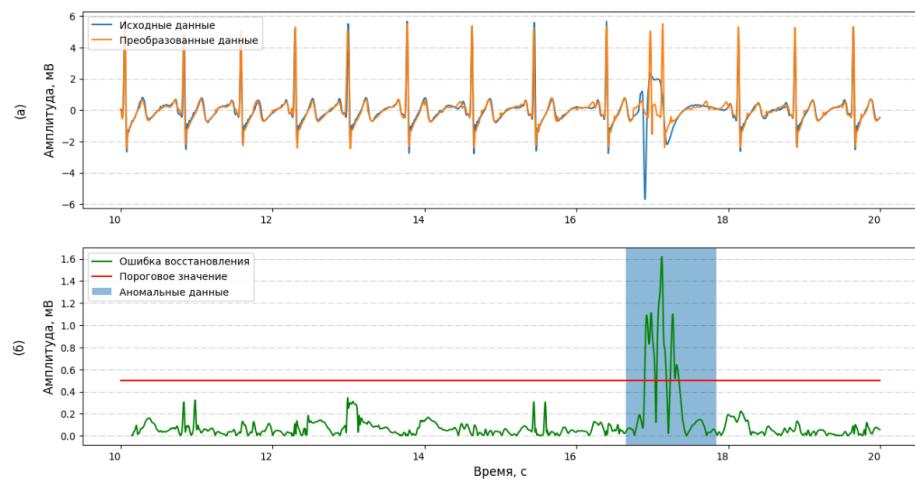


Рисунок 8 – Обнаружение аномальных участков в данных

Изм.	Лист	№ докум	Подпись	Дата	Лист
					5